

0. NOTATION & GRUNDLAGEN

Typografie & Dimensionen


- Skalare:  $x, \alpha \in \mathbb{R}$  (normal)
- Vektoren (Standard = Spaltenvektor):  
 $x \in \mathbb{R}^{n \times 1}$  bzw. Transponiert  $x^T \in \mathbb{R}^{1 \times n}$
- Matrizen:  $X \in \mathbb{R}^{m \times n}$  (Zeilen  $m$ , Spalten  $n$ ), Eintrag:  $X_{ij}$

Matrix-Vektor-Multiplikation

- Dimensions-Check:  $(m \times n) \cdot (n \times 1) \Rightarrow (m \times 1)$
- Regel: Innere Dimensionen ( $n$ ) müssen gleich sein.

Kochbuch-Berechnung:

- Zeile  $i$  im Ergebnis = Skalarprodukt aus  $i$ -ter Zeile von  $A$  und Vektor  $x$ .
- Formel:  $y_i = \sum_{j=1}^n A_{ij} x_j$



$y_i = \sum_k M_{ik} x_k$

Kronecker-Delta  $\delta_{ij}$

- Definition:  $\delta_{ij} = 1$  falls  $i = j$ , sonst 0.
- 3 goldene Prüfungs-Regeln:
  - Matrix-Äquivalent: Einheitsmatrix  $I = (\delta_{ij})$
  - Ableitung von Vektoren:  $\partial \frac{x_i}{\partial x_j} = \delta_{ij}$
  - Filter-Regel:  $\sum_j \delta_{ij} f(j) = f(i)$

Bsp:  $\sum_{k=1}^n \delta_{km} U_{ki} = U_{mi}$

Mitternachtsformel (a-b-c-Formel)

Löse  $ax^2 + bx + c = 0$  über:

$$x_{1,2} = \frac{-b \pm \sqrt{b^2 - 4ac}}{2a}$$

1. VEKTOREN: LINEARKOMBINATION & UNABHÄNGIGKEIT

Linearkombination (LK)

- $v = \lambda_1 v_1 + \dots + \lambda_k v_k$
- Kochbuch (LGS): Matrix  $[A \mid v]$  aufstellen (Vektoren als Spalten) und mit Gauss lösen:
  - Lösbar  $\Rightarrow$  Ja (ist LK)
  - Widerspruch (z.B.  $0 = c$ )  $\Rightarrow$  Nein (keine LK)
  - Bsp:  $\begin{pmatrix} 1 & 2 & 5 \\ 0 & 1 & 2 \end{pmatrix} \Rightarrow$  lösbar.

Lineare Unabhängigkeit (LU)

- $\sum \lambda_i v_i = 0 \Rightarrow \lambda_1 = \dots = \lambda_k = 0$  (nur triviale Lösung)
- Kochbuch (Vektoren als Spalten in Matrix  $A$ ):
  - Bringe  $[A \mid 0]$  mit Gauss auf Zeilenstufenform.
  - Jede Spalte hat ein Pivot-Element  $\Rightarrow$  LU
  - Spalte ohne Pivot (Nullzeile)  $\Rightarrow$  LA

Bsp:  $v_1 = \begin{pmatrix} 1 \\ 0 \\ 2 \end{pmatrix}, v_2 = \begin{pmatrix} 2 \\ 1 \\ 0 \end{pmatrix}, v_3 = \begin{pmatrix} 0 \\ -1 \\ 4 \end{pmatrix} \Rightarrow [A \mid 0] =$

$\begin{pmatrix} 1 & 2 & 0 & | & 0 \\ 0 & 1 & -1 & | & 0 \\ 2 & 0 & 4 & | & 0 \end{pmatrix} \xrightarrow{\text{Gauss}} \begin{pmatrix} 1 & 2 & 0 & | & 0 \\ 0 & 1 & -1 & | & 0 \\ 0 & -4 & 4 & | & 0 \end{pmatrix} \Rightarrow$  Spalte 2 ohne Pivot  $\Rightarrow$  LA.

2. MULTIVARIATE ABLEITUNGEN

Gradient  $\nabla f$  (Skalar  $\rightarrow$  Vektor)

- $f: \mathbb{R}^n \rightarrow \mathbb{R}$  (Spaltenvektor der partiellen Ableitungen).
- Bsp:  $f(x, y) = x^2 y + 3y \Rightarrow \partial_x f = 2xy, \partial_y f = x^2 + 3 \Rightarrow \nabla f(x, y) = \begin{pmatrix} 2xy \\ x^2 + 3 \end{pmatrix}$
- Vektor-Gradienten:
  - $\nabla \|x\| = \frac{x^T}{\|x\|}$
  - $\nabla(x^T x) = \nabla \|x\|^2 = 2 \cdot \|x\| \cdot \frac{x^T}{\|x\|} = 2x^T$
  - (Hinweis:  $x^T x$  ist reell.  $\|x\| = (\sum_{i=1}^n x_i^2)^{\frac{1}{2}} = \sqrt{x^T x}$  und  $\frac{1}{\|x\|} = (\sum_{i=1}^n x_i^2)^{-\frac{1}{2}}$ )

Jacobi-Matrix  $J_f$  (Vektor  $\rightarrow$  Matrix)

$f: \mathbb{R}^n \rightarrow \mathbb{R}^m$  (Grösse  $m \times n$ ). Zeile  $i =$  Ableitungen von  $f_i$  nach allen Variablen.

Bsp:  $f(x, y) = \begin{pmatrix} x^2 y \\ 5x + y \end{pmatrix} \Rightarrow J_f = \begin{pmatrix} \frac{\partial f_1}{\partial x_1}(P) & \dots & \frac{\partial f_1}{\partial x_n}(P) \\ \vdots & \ddots & \vdots \\ \frac{\partial f_m}{\partial x_1}(P) & \dots & \frac{\partial f_m}{\partial x_n}(P) \end{pmatrix}$   
(Hinweis:  $\nabla f = J_f^T$ )

Mehrdimensionale Kettenregel

$J_{f \circ g}(x) = J_{f(g(x))} \cdot J_g(x)$   
Für 3 + Funktionen:  
 $J_{f \circ g \circ h}(x) = J_{f(g(h(x)))} \cdot J_{g(h(x))} \cdot J_h(x)$   
(Matrizenmultiplikation von links nach rechts)

Kochbuch-Bsp (Ableitung entlang Kurve):

- Gegeben  $f(x, y) = x \cdot y$  und Kurve  $c(t) = \begin{pmatrix} t^2 \\ 3t \end{pmatrix}$ . Gesucht  $\frac{d}{dt} f(c(t))$ :
- Äussere Ableitung:  $J_f(x, y) = \begin{pmatrix} y & x \end{pmatrix}$
  - Kurve in  $J_f$  einsetzen:  $J_f(c(t)) = \begin{pmatrix} 3t & t^2 \end{pmatrix}$
  - Innere Ableitung:  $J_c(t) = c'(t) = \begin{pmatrix} 2t \\ 3 \end{pmatrix}$
  - Multiplikation:  $\begin{pmatrix} 3t & t^2 \end{pmatrix} \cdot \begin{pmatrix} 2t \\ 3 \end{pmatrix} = 3t \cdot 2t + t^2 \cdot 3 = 9t^2$

Mehrdimensionale Linearisierung

Approximation 1. Ordnung von  $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$  an der Stelle  $a \in \mathbb{R}^n$ :

$f(x) \approx f(a) + J_f(a) \cdot (x - a)$

Bsp:  $f(x, y) = \begin{pmatrix} x^2 + y^2 \\ xy \end{pmatrix}$  an der Stelle  $a = \begin{pmatrix} 1 \\ 2 \end{pmatrix}$ .

- $f(a) = \begin{pmatrix} 1^2 + 2^2 \\ 1 \cdot 2 \end{pmatrix} = \begin{pmatrix} 5 \\ 2 \end{pmatrix}$
- Jacobi:  $J_f(x, y) = \begin{pmatrix} 2x & 2y \\ y & x \end{pmatrix} \Rightarrow J_f(a) = \begin{pmatrix} 2 & 4 \\ 2 & 1 \end{pmatrix}$
- Formel:

$\tilde{f}(x, y) = \begin{pmatrix} 5 \\ 2 \end{pmatrix} + \begin{pmatrix} 2 & 4 \\ 2 & 1 \end{pmatrix} \begin{pmatrix} x-1 \\ y-2 \end{pmatrix} = \begin{pmatrix} 2x + 4y - 5 \\ 2x + y - 2 \end{pmatrix}$

- Approx. für  $x = \begin{pmatrix} 1.01 \\ 1.98 \end{pmatrix}$  (nahe  $a$ ):

$\tilde{f}(1.01, 1.98) = \begin{pmatrix} 5 \\ 2 \end{pmatrix} + \begin{pmatrix} 2 & 4 \\ 2 & 1 \end{pmatrix} \begin{pmatrix} 0.01 \\ -0.02 \end{pmatrix} = \begin{pmatrix} 4.94 \\ 2.00 \end{pmatrix}$

(Exakt:  $f(1.01, 1.98) = \begin{pmatrix} 4.9405 \\ 1.9998 \end{pmatrix}$ )

3. OPTIMIERUNG: STATIONÄRE PUNKTE & HESSE-MATRIX

Ziel: Lokale Extrema finden & klassifizieren für  $f(x, y)$ .

- Bsp:  $f(x, y) = x^3 - 12x + y^2$

- Stationäre Punkte:  $\nabla f(x, y) = \begin{pmatrix} 3x^2 - 12 \\ 2y \end{pmatrix} \stackrel{!}{=} \begin{pmatrix} 0 \\ 0 \end{pmatrix} \Rightarrow 3x^2 - 12 = 0 \Rightarrow x_{1,2} = \pm 2$  und  $2y = 0 \Rightarrow y = 0$ . Kandidaten:  $P_1(2, 0), P_2(-2, 0)$ 
  - LGS-Lösungsstrategien für  $\nabla f = 0$ :
    - S1: Ausklammern & Nullprodukt (Trick): Nie durch Variable teilen!  $xy = 2x \Rightarrow xy - 2x = 0 \Rightarrow x(y - 2) = 0 \Rightarrow$  Fall 1:  $x = 0$ , Fall 2:  $y = 2$ . Fälle einzeln in andere Gleichung einsetzen.
    - S2: Einsetzungsverfahren (Zuverlässig): Einfachste Gleichung nach einer Variable auflösen und in andere einsetzen. Bsp:  $2x - y = 0 \Rightarrow y = 2x$  in (II) einsetzen.
    - S3: Subtraktion (Symmetrie-Trick): Bei fast identischen Gleichungen (I) - (II) rechnen. Oft entsteht  $x^2 - y^2 = (x - y)(x + y) = 0 \Rightarrow$  S1 anwenden.

2. Hesse-Matrix:

$H_f(x, y) = \begin{pmatrix} f_{xx} & f_{xy} \\ f_{yx} & f_{yy} \end{pmatrix}$

(Symmetrisch, da  $f_{xy} = f_{yx}$ )

Bsp:  $H_f(x, y) = \begin{pmatrix} 6x & 0 \\ 0 & 2 \end{pmatrix}$

3. Definitheit (über quadratische Form):

Hesse-Matrix  $H_f = \begin{pmatrix} a & b & d \\ b & c & e \\ d & e & f \end{pmatrix}$  aufstellen  $\rightarrow$  quadratische Form:

$q(u, v, w) = \begin{pmatrix} u & v & w \end{pmatrix} \begin{pmatrix} a & b & d \\ b & c & e \\ d & e & f \end{pmatrix} \begin{pmatrix} u \\ v \\ w \end{pmatrix} = au^2 + cv^2 + fw^2 + 2buv + 2dvw + 2evw$

Bringe durch quadratisches Ergänzen in die Form  $c_1(u + \dots)^2 + c_2(v + \dots)^2 + c_3w^2$ :

- Nur plus (+)  $\Rightarrow$  positiv definit  $\Rightarrow$  Minimum
- Nur minus (-)  $\Rightarrow$  negativ definit  $\Rightarrow$  Maximum
- Beides (+ und -)  $\Rightarrow$  indefinit  $\Rightarrow$  Sattelpunkt
- Klassifikation Bsp:
  - $P_1(2, 0): H_f(2, 0) = \begin{pmatrix} 12 & 0 \\ 0 & 2 \end{pmatrix} \Rightarrow q(u, v) = \begin{pmatrix} u & v \end{pmatrix} \begin{pmatrix} 12 & 0 \\ 0 & 2 \end{pmatrix} \begin{pmatrix} u \\ v \end{pmatrix} = 6u^2 + v^2$  (nur +)  $\Rightarrow$  Minimum
  - $P_2(-2, 0): H_f(-2, 0) = \begin{pmatrix} -12 & 0 \\ 0 & 2 \end{pmatrix} \Rightarrow q(u, v) = \begin{pmatrix} u & v \end{pmatrix} \begin{pmatrix} -12 & 0 \\ 0 & 2 \end{pmatrix} \begin{pmatrix} u \\ v \end{pmatrix} = -6u^2 + v^2$  (beides)  $\Rightarrow$  Sattelpunkt
- Contour Plots (Höhenlinien):
  - Minima/Maxima: Zentren geschlossener Ringe/Ellipsen.
  - Sattelpunkte: Kreuzungen/Einschnürungen zw. Bergen & Tälern.

Quadratische Ergänzung

- 1D-Ergänzung:

$f(x) = \frac{2x^2 - 4x + 3}{x^2 - 2x} = 2 \frac{x^2 - 2x + 1.5}{x^2 - 2x} = 2 \frac{(x-1)^2 - 0.5}{x^2 - 2x} = 2 \left( \frac{(x-1)^2}{x^2 - 2x} - \frac{0.5}{x^2 - 2x} \right) + 3$

- Mehrdimensionale Expansion: (Es müssen immer alle Kombinationen vorhanden sein)

Das Ergebnis für vier Terme  $(a + b + c + d)^2$  lautet ausmultipliziert:

$a^2 + b^2 + c^2 + d^2 + 2ab + 2ac + 2ad + 2bc + 2bd + 2cd$


4. THEORIE: PDF, CDF & MAXIMUM LIKELIHOOD (MLE)

A. Wahrscheinlichkeitsdichte (PDF:  $f(x)$ )

- Bedingung 1:  $f(x) \geq 0$  (nie negativ)
- Bedingung 2 (Fläche = 1):  $\int_{-\infty}^{\infty} f(x) dx = 1$


B. Kumulative Verteilungsfunktion (CDF:  $F(x)$ )

- Definition:  $F(x) = P(X \leq x) = \int_{-\infty}^x f(t) dt$
- Eigenschaften:  $F(-\infty) = 0, F(\infty) = 1$  (monoton steigend)
- Zusammenhang:  $f(x) = \frac{d}{dx} F(x)$  (Dichte ist Ableitung der CDF)



C. Stetige Gleichverteilung unif(a,b)

- Dichte (PDF):  $f(x) = \frac{1}{b-a}$  für  $a \leq x \leq b$ , sonst 0
- Verteilung (CDF):  $F_X(x) = \frac{x-a}{b-a}$  für  $a < x < b$



D. Statistische Unabhängigkeit  $X, Y$  unabhängig  $\Leftrightarrow f_{X,Y}(x, y) = f_X(x) \cdot f_Y(y)$  (sonst abhängig)

- Bsp:  $f_{X(x)} = \frac{1}{2} \cdot \mathbb{1}_{(0,2)}(x)$  und  $f_{Y(y)} = \frac{1}{3} \cdot \mathbb{1}_{(0,3)}(y)$ . Da  $f_X(x) \cdot f_Y(y) = \frac{1}{6} \cdot \mathbb{1}_{(0,2)}(x) \cdot \mathbb{1}_{(0,3)}(y) \neq \frac{1}{6} \cdot \mathbb{1}_{(0,6)}(xy) = f_{X,Y}(x, y)$ , sind sie **abhängig**. (Gegenbsp:  $f_{X(1)} \cdot f_{Y(5)} = \frac{1}{2} \cdot 0 = 0$ , aber  $f_{X,Y}(1, 5) = \frac{1}{6} \cdot \mathbb{1}_{(0,6)}(5) = \frac{1}{6} \neq 0$ )

E. Maximum Likelihood Estimation (MLE) Ziel: Parameter  $\theta$  finden, die die Wahrscheinlichkeit der Stichprobe maximieren. Kochbuch (4 Schritte):

- Likelihood  $L(\theta)$  aufstellen:  $L(\theta) = \prod_{i=1}^n f(x_i; \theta)$
- Log-Likelihood  $\ell(\theta)$  (In anwenden):
  - $\ell(\theta) = \ln(L(\theta)) = \sum_{i=1}^n \ln(f(x_i; \theta))$  (Aus Produkt wird Summe)
  - (Kostenfunktion) / Neg. Log-Likelihood:  $c(\theta) = -\ell(\theta) = -\sum \ln(f(x_i; \theta))$
- Ableiten:  $\frac{\partial}{\partial \theta} \ell(\theta)$  berechnen.
- Nullsetzen & Auflösen:  $\frac{\partial}{\partial \theta} \ell(\theta) \stackrel{!}{=} 0 \Rightarrow \hat{\theta}_{MLE}$

Bernoulli-Likelihood (k Erfolge in n Versuchen):

$L(p) = p^k \cdot (1 - p)^{n-k}$

5. KOCHBUCH: DIE WICHTIGSTEN AUFGABENTYPEN

Typ 1: Normalisierung (Konstante  $c$  finden)

- Geg:  $f(x) = c \cdot g(x)$  im Intervall  $[a, b]$
- Schritt 1: Integral = 1 setzen:  $c \cdot \int_a^b g(x) dx = 1$
- Schritt 2: Integral berechnen:  $K = \int_a^b g(x) dx$
- Schritt 3: Nach  $c$  auflösen:  $c \cdot K = 1 \Rightarrow c = \frac{1}{K}$

Typ 2: Wahrscheinlichkeit im Intervall ( $P(a \leq X \leq b)$ )

- Schritt 1: Integral der PDF von  $a$  bis  $b$  berechnen:

$P(a \leq X \leq b) = \int_a^b f(x) dx$

Typ 3: Die CDF  $F(x)$  herleiten

- Geg:  $f(x)$  ab Startwert  $a$
- Schritt 1: Dummy-Variable  $t$  nutzen. Integral aufstellen:

$F(x) = \int_a^x f(t) dt$

- Schritt 2: Integrieren, Obergrenze  $x$  und Untergrenze  $a$  einsetzen.
- Schritt 3: Formal korrekt aufschreiben:

$F(x) = \begin{cases} 0 & \text{für } x < a \\ \text{Ergebnis für } x \geq a \end{cases}$

Typ 4: Mit der CDF Wahrscheinlichkeiten berechnen

- Geg:  $F(x)$  bekannt. Gesucht:  $P(a < X \leq b)$
- Schritt 1: Obere minus untere Grenze einsetzen:

$P(a < X \leq b) = F(b) - F(a)$

(Kein Integrieren mehr!)

Typ 5: Erwartungswert  $E(X)$  berechnen

- Schritt 1: Integral über  $x \cdot f(x)$  aufstellen:

$E(X) = \int_{-\infty}^{\infty} x \cdot f(x) dx$

Typ 8: Uneigentliche Integrale (z.B.  $P(X > a)$ )

- Weg 1 (Integral):  $\int_a^{\infty} f(x) dx$ . Stammfunktion bilden, Obergrenze  $\infty$  einsetzen. Tipp:  $e^{-\infty} = 0, \frac{1}{\infty} = 0$ .

**Weg 2 (Schneller, falls  $F(x)$  bekannt):** Gegenwahrscheinlichkeit nutzen:

$$P(X > a) = 1 - P(X \leq a) = 1 - F(a)$$

**Typ 9: Variablentransformation ( $Y = g(X)$ )**

- Geg: Dichte  $f_X(x)$  auf  $[a, b]$ , Transformation  $y = g(x)$ . Gesucht:  $f_Y(y)$
- Grenzen:** Alte Grenzen  $[a, b]$  in  $g(x)$  einsetzen:
  - Wenn  $g$  steigend:  $[g(a), g(b)]$  ! Wenn  $g$  fallend:  $[g(b), g(a)]$
- Schritt 1 (Umkehrfunktion):** Löse  $y = g(x)$  nach  $x$  auf:

$$x = g^{-1}(y)$$

- Schritt 2 (Ableitung):** Leite  $x$  nach  $y$  ab:

$$\frac{dx}{dy} = \frac{d}{dy} g^{-1}(y)$$

- Schritt 3 (Formel & Einsetzen):**

$$f_Y(y) = f_X(g^{-1}(y)) \cdot \left| \frac{dx}{dy} \right|$$

- Bsp:**  $f_X(x) = \frac{1}{2}$  auf  $[0, 2]$  und  $y = x^2$  ( $x \geq 0$ ):
  - Grenzen:  $x \in [0, 2] \Rightarrow y \in [0^2, 2^2] = [0, 4]$
  - Schritt 1:  $x = \sqrt{y}$
  - Schritt 2:  $\frac{dx}{dy} = \frac{1}{2\sqrt{y}}$
  - Schritt 3:  $f_Y(y) = f_X(\sqrt{y}) \cdot \left| \frac{1}{2\sqrt{y}} \right| = \frac{1}{2} \cdot \frac{1}{2\sqrt{y}} = \frac{1}{4\sqrt{y}}$  auf  $[0, 4]$
- Weg 2 (CDF-Methode, z.B. für  $Y = X^p$ ):**
  - CDF aufstellen:  $F_{Y(y)} = P(Y \leq y) = P(X^p \leq y) = P\left(X \leq y^{\frac{1}{p}}\right) = F_X\left(y^{\frac{1}{p}}\right)$
  - PDF durch Ableiten finden:  $f_{Y(y)} = \frac{d}{dy} F_{Y(y)}$

**6. NUMERISCHE OPTIMIERUNG: GRADIENT DESCENT & NEWTON**

- A. Gradientenabstieg (Gradient Descent)**
- Ziel:** Iterativ ein lokales Minimum finden.
- Formel:**

$$\mathbf{x}_{k+1} = \mathbf{x}_k - \alpha \cdot \nabla f(\mathbf{x}_k)$$

- mit  $\alpha$  = Lernrate / Step Size  $> 0$
- Kochbuch-Bsp:**  $f(x, y) = x^2 + 2y^2$ , Startwert  $\mathbf{x}_0 = \begin{pmatrix} 2 \\ 1 \end{pmatrix}$ , Lernrate  $\alpha = 0.1$ . Gesucht  $\mathbf{x}_1$ :
  - Gradient allgemein:  $\nabla f(x, y) = \begin{pmatrix} 2x \\ 4y \end{pmatrix}$
  - $\mathbf{x}_0$  einsetzen:  $\nabla f(2, 1) = \begin{pmatrix} 4 \\ 4 \end{pmatrix}$
  - Formel anwenden:

$$\begin{aligned} \mathbf{x}_1 &= \begin{pmatrix} 2 \\ 1 \end{pmatrix} - 0.1 \cdot \begin{pmatrix} 4 \\ 4 \end{pmatrix} \\ &= \begin{pmatrix} 2 \\ 1 \end{pmatrix} - \begin{pmatrix} 0.4 \\ 0.4 \end{pmatrix} = \begin{pmatrix} 1.6 \\ 0.6 \end{pmatrix} \end{aligned}$$

- Verhalten im Contour Plot:** Bewegung immer orthogonal (senkrecht) zu den Höhenlinien in Richtung des tiefsten Punktes. Bei zu grosser Lernrate  $\alpha$  kann das Minimum übersprungen werden.
- Fehlende globale Konvergenz (3 Szenarien):**
  - Lokales statt globales Minimum:**
    - Häufigkeit: Sehr wahrscheinlich bei mehreren Minima.
    - Fix: Verschiedene Startpunkte wählen.
  - Sattelpunkt / Maximum (stat. Punkt):**
    - Häufigkeit: Sehr unwahrscheinlich.
    - Fix: Anderen Startpunkt wählen.
  - Overshooting / Keine Konvergenz:**
    - Häufigkeit: Wahrscheinlich bei grosser Lernrate  $\alpha$  (v.a. in engen Tälern).
    - Fix: Kleinere Lernrate  $\alpha$  wählen.

**B. Newton-Verfahren (Newton's Method)**

- Variante 1: Nullstellensuche (1D):**  $f(x) = 0$

$$\mathbf{x}_{k+1} = \mathbf{x}_k - \frac{f(\mathbf{x}_k)}{f'(\mathbf{x}_k)}$$

**Bsp:**  $f(x) = x^2 - 5x + 2$ . Gesucht  $x_1$ :  $f'(x) = 2x \Rightarrow x_1 = 2 - \frac{2^2 - 5}{2 \cdot 2} = 2 - \frac{-1}{4} = 2.25$

- Variante 2: Minimumsuche (Multivariat):**  $\nabla f = 0$
- Newton-Formel:**

$$\mathbf{x}_{k+1} = \mathbf{x}_k - [H_f(\mathbf{x}_k)]^{-1} \cdot \nabla f(\mathbf{x}_k)$$

- Hilfsformeln (Komponenten):**
  - Gradient:  $\nabla f(x, y) = \begin{pmatrix} f_x \\ f_y \end{pmatrix} = \begin{pmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \end{pmatrix}$
  - Hesse-Matrix:  $H_f(x, y) = \begin{pmatrix} f_{xx} & f_{xy} \\ f_{yx} & f_{yy} \end{pmatrix}$
- Diagonal-Matrix Invertierungs-Trick:**

$$\begin{pmatrix} a & 0 \\ 0 & b \end{pmatrix}^{-1} = \begin{pmatrix} \frac{1}{a} & 0 \\ 0 & \frac{1}{b} \end{pmatrix}$$

- (Kehrwerte der Diagonalelemente)
- Bsp:** Geg:  $f(x, y) = x^2 + 2y^2 + 4y$ , Startwert  $\mathbf{x}_0 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$ . Gesucht  $\mathbf{x}_1$ :
  - Gradient & Hesse-Matrix allgemein:

- $\nabla f(x, y) = \begin{pmatrix} 2x \\ 4y + 4 \end{pmatrix}, H_f(x, y) = \begin{pmatrix} 2 & 0 \\ 0 & 4 \end{pmatrix}$
- Punkt einsetzen:  $\nabla f(1, 1) = \begin{pmatrix} 2 \\ 8 \end{pmatrix}, H_f(1, 1) = \begin{pmatrix} 2 & 0 \\ 0 & 4 \end{pmatrix}$
- $H_f$  invertieren (Diagonal-Trick):  $[H_f(1, 1)]^{-1} = \begin{pmatrix} \frac{1}{2} & 0 \\ 0 & \frac{1}{4} \end{pmatrix}$
- Schritt berechnen ( $\Delta \mathbf{x} = -H_f^{-1} \cdot \nabla f$ ):

$$\Delta \mathbf{x} = - \begin{pmatrix} \frac{1}{2} & 0 \\ 0 & \frac{1}{4} \end{pmatrix} \begin{pmatrix} 2 \\ 8 \end{pmatrix} = \begin{pmatrix} -\frac{1}{2} \cdot 2 \\ -\frac{1}{4} \cdot 8 \end{pmatrix} = \begin{pmatrix} -1 \\ -2 \end{pmatrix}$$

- Update:  $\mathbf{x}_1 = \begin{pmatrix} 1 \\ 1 \end{pmatrix} + \begin{pmatrix} -1 \\ -2 \end{pmatrix} = \begin{pmatrix} 0 \\ -1 \end{pmatrix}$
- Alternativer Newton-Schritt über LGS (Extended):** Löse  $H_f \cdot \Delta \mathbf{x} = -\nabla f$  nach  $\Delta \mathbf{x}$  auf (z.B. mit Gauss-LGS), falls  $H_f$  nicht einfach invertierbar ist.

- Hesse-Matrix Operationen:**
- Transponieren:** Da  $H_f$  symmetrisch ist ( $f_{xy} = f_{yx}$ ), gilt immer  $H_f^T = H_f$  (allgemein: Zeilen & Spalten vertauschen).
- 2x2 Invertieren:**  $\begin{pmatrix} a & b \\ c & d \end{pmatrix}^{-1} = \frac{1}{ad-bc} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}$

**ABLEITUNGSREGELN**

| Funktion $f(x)$     | Ableitung $f'(x) = \frac{d}{dx} f(x)$                                                                        |
|---------------------|--------------------------------------------------------------------------------------------------------------|
| c (Konstante)       | 0                                                                                                            |
| $x^n$               | $nx^{n-1}$                                                                                                   |
| $e^x$               | $e^x$                                                                                                        |
| $e^{g(x)}$          | $g'(x)e^{g(x)}$ (Kettenregel)                                                                                |
| $\ln(x)$            | $\frac{1}{x}$                                                                                                |
| $\ln(g(x))$         | $g' \cdot \frac{x}{g(x)}$ (Log-Trick)                                                                        |
| $\sin(x)$           | $\cos(x)$                                                                                                    |
| $\cos(x)$           | $-\sin(x)$                                                                                                   |
| $\tan(x)$           | $\frac{1}{\cos^2(x)} = 1 + \tan^2(x)$                                                                        |
| $\arcsin(x)$        | $\frac{1}{\sqrt{1-x^2}}$                                                                                     |
| $\arccos(x)$        | $-\frac{1}{\sqrt{1-x^2}}$                                                                                    |
| Sigmoid $\sigma(x)$ | $\sigma(x)(1 - \sigma(x))$ mit $\sigma(x) = \frac{1}{1+e^{-x}}$                                              |
| $\ln(\sigma(x))$    | $1 - \sigma(x)$ (FS23)                                                                                       |
| Produktregel        | $(uv)' = u'v + uv'$                                                                                          |
| Quotientenregel     | $\left(\frac{u}{v}\right)' = \frac{u'v - uv'}{v^2}$                                                          |
| Totale Ableitung    | $\frac{d}{dt} f = \frac{\partial f}{\partial x} \frac{dx}{dt} + \frac{\partial f}{\partial y} \frac{dy}{dt}$ |

**INTEGRATIONSREGELN**

| Funktion $f(x)$ | Integral $\int f(x) dx$   |
|-----------------|---------------------------|
| 0               | C (Integrationskonstante) |

| Funktion $f(x)$       | Integral $\int f(x) dx$                                              |
|-----------------------|----------------------------------------------------------------------|
| $x^n$ ( $n \neq -1$ ) | $\frac{x^{n+1}}{n+1} + C$                                            |
| $\frac{1}{x}$         | $\ln x  + C$                                                         |
| $e^x$                 | $e^x + C$                                                            |
| $e^{ax}$              | $\frac{1}{a} e^{ax} + C$                                             |
| $\sin(x)$             | $-\cos(x) + C$                                                       |
| $\cos(x)$             | $\sin(x) + C$                                                        |
| $\frac{1}{\cos^2(x)}$ | $\tan(x) + C$                                                        |
| $\arcsin(x)$          | $x \arcsin(x) + \sqrt{1-x^2} + C$                                    |
| $\arccos(x)$          | $x \arccos(x) - \sqrt{1-x^2} + C$                                    |
| $\frac{a}{x^{a+1}}$   | $-x^{-a} + C$ (FS25)                                                 |
| Part. Integration     | $\int uv' dx = uv - \int u'v dx$                                     |
| Substitution          | $\int f(g(x))g'(x) dx = \int f(u) du$                                |
| Uneigntl. Int.        | $\int_1^\infty \left(\frac{a}{x^{a+1}}\right) dx = 1$ (für $a > 0$ ) |


**LOGARITHMUSGESETZE**

| Regel          | Formel                                                     |
|----------------|------------------------------------------------------------|
| Multiplikation | $\ln(a \cdot b) = \ln(a) + \ln(b)$                         |
| Division       | $\ln\left(\frac{a}{b}\right) = \ln(a) - \ln(b)$            |
| Potenzierung   | $\ln(a^b) = b \cdot \ln(a)$                                |
| Konstante 1    | $\ln(1) = 0$                                               |
| Konstante e    | $\ln(e) = 1$                                               |
| Basiswechsel   | $\log_b(a) = \frac{\ln(a)}{\ln(b)}$                        |
| Spezialfälle   | $e^{-\ln(2)} = \frac{1}{2} \quad   \quad \ln(e^{-2}) = -2$ |

**7. MACHINE LEARNING: AKTIVIERUNGEN & LOSSES**

- Aktivierungsfunktionen**
- Sigmoid (Binary Classification):**

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$



- Ableitung:  $\sigma'(z) = \sigma(z)(1 - \sigma(z))$
- Softmax (Multi-Class Classification):** Für Vektor  $\mathbf{z} \in \mathbb{R}^K$ :

$$\text{Softmax}(\mathbf{z})_i = \frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}}$$

- Loss-Funktionen (Kostenfunktionen)**
- Log Loss / Binary Cross-Entropy (BCE):** Für Wahrscheinlichkeit  $p = \sigma(z)$  und wahres Label  $y \in \{0, 1\}$ :

$$\mathcal{L}_{\text{BCE}(y,p)} = -y \ln(p) - (1 - y) \ln(1 - p)$$

- Multi-Class Cross-Entropy (CE):** Für Vorhersagen  $p_i = \text{Softmax}(\mathbf{z})_i$  und wahre Wahrscheinlichkeiten  $y_i$  (One-Hot):

$$\mathcal{L}_{\text{CE}(y,p)} = - \sum_{i=1}^K y_i \ln(p_i)$$

- Prüfungs-Shortcut (Gradient bzgl. Logit  $z_i$ ):** Gilt bei BCE+Sigmoid sowie CE+Softmax:

$$\frac{\partial \mathcal{L}}{\partial z_i} = p_i - y_i$$

**TRIGONOMETRISCHE WERTE**

$$\tan(x) = \frac{\sin(x)}{\cos(x)}$$

| $\alpha$       | 0° | π/6                  | π/4                  | π/3                  | π/2 | 2π/3                  | 3π/4                  | 5π/6                  | π    | 7π/6                  | 5π/4                  | 4π/3                  | 3π/2 | 5π/3                  | 7π/4                  | 11π/6                 | 2π   |
|----------------|----|----------------------|----------------------|----------------------|-----|-----------------------|-----------------------|-----------------------|------|-----------------------|-----------------------|-----------------------|------|-----------------------|-----------------------|-----------------------|------|
| $\alpha^\circ$ | 0° | 30°                  | 45°                  | 60°                  | 90° | 120°                  | 135°                  | 150°                  | 180° | 210°                  | 225°                  | 240°                  | 270° | 300°                  | 315°                  | 330°                  | 360° |
| $\sin \alpha$  | 0  | $\frac{1}{2}$        | $\frac{\sqrt{2}}{2}$ | $\frac{\sqrt{3}}{2}$ | 1   | $\frac{\sqrt{3}}{2}$  | $\frac{\sqrt{2}}{2}$  | $\frac{1}{2}$         | 0    | $-\frac{1}{2}$        | $-\frac{\sqrt{2}}{2}$ | $-\frac{\sqrt{3}}{2}$ | -1   | $-\frac{\sqrt{3}}{2}$ | $-\frac{\sqrt{2}}{2}$ | $-\frac{1}{2}$        | 0    |
| $\cos \alpha$  | 1  | $\frac{\sqrt{3}}{2}$ | $\frac{\sqrt{2}}{2}$ | $\frac{1}{2}$        | 0   | $-\frac{1}{2}$        | $-\frac{\sqrt{2}}{2}$ | $-\frac{\sqrt{3}}{2}$ | -1   | $-\frac{\sqrt{3}}{2}$ | $-\frac{\sqrt{2}}{2}$ | $\frac{1}{2}$         | 0    | $\frac{1}{2}$         | $\frac{\sqrt{2}}{2}$  | $\frac{\sqrt{3}}{2}$  | 1    |
| $\tan \alpha$  | 0  | $\frac{1}{\sqrt{3}}$ | 1                    | $\sqrt{3}$           | -   | $-\sqrt{3}$           | -1                    | $-\frac{1}{\sqrt{3}}$ | 0    | $\frac{1}{\sqrt{3}}$  | 1                     | $\sqrt{3}$            | -    | $-\sqrt{3}$           | -1                    | $-\frac{1}{\sqrt{3}}$ | 0    |
| $\cot \alpha$  | -  | $\sqrt{3}$           | 1                    | $\frac{1}{\sqrt{3}}$ | 0   | $-\frac{1}{\sqrt{3}}$ | -1                    | $-\sqrt{3}$           | -    | $\sqrt{3}$            | 1                     | $\frac{1}{\sqrt{3}}$  | 0    | $-\frac{1}{\sqrt{3}}$ | -1                    | $-\sqrt{3}$           | -    |

**WICHTIGE KONSTANTEN & GRENZWERTE**

| Ausdruck / Limes                                             | Wert              |
|--------------------------------------------------------------|-------------------|
| $e^0$                                                        | 1                 |
| $e^1$                                                        | $e \approx 2.718$ |
| $e^{-1} = \frac{1}{e}$                                       | $\approx 0.368$   |
| $\pi$                                                        | $\approx 3.1415$  |
| $\sqrt{2}$                                                   | $\approx 1.414$   |
| $\sqrt{3}$                                                   | $\approx 1.732$   |
| $\lim_{x \rightarrow \infty} \frac{1}{x}$                    | 0                 |
| $\lim_{x \rightarrow 0^+} \frac{1}{x}$                       | $+\infty$         |
| $\lim_{x \rightarrow 0^-} \frac{1}{x}$                       | $-\infty$         |
| $\lim_{x \rightarrow \infty} e^x$                            | $\infty$          |
| $\lim_{x \rightarrow -\infty} e^x$                           | 0                 |
| $\lim_{x \rightarrow \infty} \ln(x)$                         | $\infty$          |
| $\lim_{x \rightarrow 0^+} \ln(x)$                            | $-\infty$         |
| $\lim_{x \rightarrow \infty} x^n e^{-x}$                     | 0                 |
| $\lim_{x \rightarrow \infty} \frac{\ln(x)}{x}$               | 0                 |
| $\lim_{x \rightarrow 0^+} x \ln(x)$                          | 0                 |
| $\lim_{x \rightarrow \infty} \left(1 + \frac{a}{x}\right)^x$ | $e^a$             |
| $\lim_{x \rightarrow \infty} \sigma(x)$                      | 1                 |
| $\lim_{x \rightarrow -\infty} \sigma(x)$                     | 0                 |