

0. NOTATION & GRUNDLAGEN


Typografie & Dimensionen

- Skalare: $x, \alpha \in \mathbb{R}$ (normal)
- Vektoren (Standard = Spaltenvektor):
 $x \in \mathbb{R}^{n \times 1}$ bzw. Transponiert $x^T \in \mathbb{R}^{1 \times n}$
- Matrizen: $X \in \mathbb{R}^{m \times n}$ (Zeilen m , Spalten n), Eintrag: X_{ij}

Matrix-Vektor-Multiplikation

- Dimensions-Check: $(m \times n) \cdot (n \times 1) \Rightarrow (m \times 1)$
- Regel: Innere Dimensionen (n) müssen gleich sein.

- Kochbuch-Berechnung:
 - Zeile i im Ergebnis = Skalarprodukt aus i -ter Zeile von A und Vektor x .
 - Formel: $y_i = \sum_{j=1}^n A_{ij} x_j$



$y_i = \sum_k M_{ik} x_k$

Kronecker-Delta (δ_{ij})

- Definition: $\delta_{ij} = 1$ falls $i = j$, sonst 0.
- 3 goldene Prüfungs-Regeln:
 - Matrix-Äquivalent: Einheitsmatrix $I = (\delta_{ij})$
 - Ableitung von Vektoren: $\partial \frac{x_i}{\partial x_j} = \delta_{ij}$
 - Filter-Regel: $\sum_j \delta_{ij} f(j) = f(i)$

Bsp: $\sum_{k=1}^n \delta_{km} U_{ki} = U_{mi}$

Mitternachtsformel (a-b-c-Formel)

Löse $ax^2 + bx + c = 0$ über:

$$x_{1,2} = \frac{-b \pm \sqrt{b^2 - 4ac}}{2a}$$

1. VEKTOREN: LINEARKOMBINATION & UNABHÄNGIG-KEIT

Linearkombination (LK)

- $v = \lambda_1 v_1 + \dots + \lambda_k v_k$
- Kochbuch (LGS): Matrix $[A \mid v]$ aufstellen (Vektoren als Spalten) und mit Gauss lösen:
 - Lösbar $\Rightarrow$ Ja (ist LK)
 - Widerspruch (z.B. $0 = c$) $\Rightarrow$ Nein (keine LK)
 - Bsp: $\begin{pmatrix} 1 & 2 & 5 \\ 0 & 1 & 2 \end{pmatrix} \Rightarrow$ lösbar.

Lineare Unabhängigkeit (LU)

- $\sum \lambda_i v_i = 0 \Rightarrow \lambda_1 = \dots = \lambda_k = 0$ (nur triviale Lösung)
- Kochbuch (Vektoren als Spalten in Matrix A):
 - Bringe $[A \mid 0]$ mit Gauss auf Zeilenstufenform.
 - Jede Spalte hat ein Pivot-Element $\Rightarrow$ LU
 - Spalte ohne Pivot (Nullzeile) $\Rightarrow$ LA

Bsp: $v_1 = \begin{pmatrix} 1 \\ 0 \\ 2 \end{pmatrix}, v_2 = \begin{pmatrix} 2 \\ 1 \\ 0 \end{pmatrix}, v_3 = \begin{pmatrix} 0 \\ -1 \\ 4 \end{pmatrix} \Rightarrow [A \mid 0] =$

$\begin{pmatrix} 1 & 2 & 0 & | & 0 \\ 0 & 1 & -1 & | & 0 \\ 2 & 0 & 4 & | & 0 \end{pmatrix} \xrightarrow{\text{Gauss}} \begin{pmatrix} 1 & 2 & 0 & | & 0 \\ 0 & 1 & -1 & | & 0 \\ 0 & -4 & 4 & | & 0 \end{pmatrix} \Rightarrow \begin{pmatrix} 1 & 2 & 0 & | & 0 \\ 0 & 1 & -1 & | & 0 \\ 0 & 0 & 0 & | & 0 \end{pmatrix} \Rightarrow$ Spalte 3 ohne Pivot $\Rightarrow$ LA.

2. MULTIVARIATE ABLEITUNGEN

Gradient ∇f (Skalar $\rightarrow$ Vektor)

- $f: \mathbb{R}^n \rightarrow \mathbb{R}$ (Spaltenvektor der partiellen Ableitungen).
- Bsp: $f(x, y) = x^2 y + 3y \Rightarrow \partial_x f = 2xy, \partial_y f = x^2 + 3 \Rightarrow \nabla f(x, y) = \begin{pmatrix} 2xy \\ x^2 + 3 \end{pmatrix}$
- Vektor-Gradienten:
 - $\nabla \|x\| = \frac{x}{\|x\|}$
 - $\nabla (x^T x) = \nabla \|x\|^2 = 2 \cdot \|x\| \cdot \frac{x^T}{\|x\|} = 2x^T$
 - (Hinweis: $x^T x$ ist eine reelle Zahl / Skalar)

Jacobi-Matrix J_f (Vektor $\rightarrow$ Matrix)

$f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ (Grösse $m \times n$). Zeile i = Ableitungen von f_i nach allen Variablen.

Bsp: $f(x, y) = \begin{pmatrix} x^2 y \\ 5x + y \end{pmatrix} \Rightarrow J_f = \begin{pmatrix} 2xy & x^2 \\ 5 & 1 \end{pmatrix}$
(Hinweis: $\nabla f = J_f^T$)

$Jak(f)_P := \begin{pmatrix} \frac{\partial f_1}{\partial x_1}(P) & \dots & \frac{\partial f_1}{\partial x_n}(P) \\ \vdots & \ddots & \vdots \\ \frac{\partial f_m}{\partial x_1}(P) & \dots & \frac{\partial f_m}{\partial x_n}(P) \end{pmatrix}$


Mehrdimensionale Kettenregel

$J_{f \circ g}(x) = J_{f(g(x))} \cdot J_{g(x)}$
Für 3 + Funktionen:
 $J_{f \circ g \circ h}(x) = J_{f(g(h(x)))} \cdot J_{g(h(x))} \cdot J_{h(x)}$
(Matrizenmultiplikation von links nach rechts)

Kochbuch-Bsp (Ableitung entlang Kurve):

Gegeben $f(x, y) = x \cdot y$ und Kurve $c(t) = \begin{pmatrix} t^2 \\ 3t \end{pmatrix}$. Gesucht $\frac{d}{dt} f(c(t))$:

- Äussere Ableitung: $J_f(x, y) = \begin{pmatrix} y & x \end{pmatrix}$
- Kurve in J_f einsetzen: $J_f(c(t)) = \begin{pmatrix} 3t & t^2 \end{pmatrix}$
- Innere Ableitung: $J_c(t) = c'(t) = \begin{pmatrix} 2t \\ 3 \end{pmatrix}$
- Multiplikation: $\begin{pmatrix} 3t & t^2 \end{pmatrix} \cdot \begin{pmatrix} 2t \\ 3 \end{pmatrix} = 3t \cdot 2t + t^2 \cdot 3 = 9t^2$



Mehrdimensionale Linearisierung

Approximation 1. Ordnung von $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ an der Stelle $a \in \mathbb{R}^n$:

$f(x) \approx f(a) + J_f(a) \cdot (x - a)$

Bsp: $f(x, y) = \begin{pmatrix} x^2 + y^2 \\ xy \end{pmatrix}$ an der Stelle $a = \begin{pmatrix} 1 \\ 2 \end{pmatrix}$.

- $f(a) = \begin{pmatrix} 1^2 + 2^2 \\ 1 \cdot 2 \end{pmatrix} = \begin{pmatrix} 5 \\ 2 \end{pmatrix}$
- Jacobi: $J_f(x, y) = \begin{pmatrix} 2x & 2y \\ y & x \end{pmatrix} \Rightarrow J_f(a) = \begin{pmatrix} 2 & 4 \\ 2 & 1 \end{pmatrix}$
- Formel:

$\tilde{f}(x, y) = \begin{pmatrix} 5 \\ 2 \end{pmatrix} + \begin{pmatrix} 2 & 4 \\ 2 & 1 \end{pmatrix} \begin{pmatrix} x-1 \\ y-2 \end{pmatrix} = \begin{pmatrix} 2x + 4y - 5 \\ 2x + y - 2 \end{pmatrix}$

- Approx. für $x = \begin{pmatrix} 1.01 \\ 1.98 \end{pmatrix}$ (nahe a):

$\tilde{f}(1.01, 1.98) = \begin{pmatrix} 5 \\ 2 \end{pmatrix} + \begin{pmatrix} 2 & 4 \\ 2 & 1 \end{pmatrix} \begin{pmatrix} 0.01 \\ -0.02 \end{pmatrix} = \begin{pmatrix} 4.94 \\ 2.00 \end{pmatrix}$

(Exakt: $f(1.01, 1.98) = \begin{pmatrix} 4.9405 \\ 1.9998 \end{pmatrix}$)

3. OPTIMIERUNG: STATIONÄRE PUNKTE & HESSE-MATRIX

Ziel: Lokale Extrema finden & klassifizieren für $f(x, y)$.

Bsp: $f(x, y) = x^3 - 12x + y^2$

- Stationäre Punkte: $\nabla f(x, y) = \begin{pmatrix} 3x^2 - 12 \\ 2y \end{pmatrix} \stackrel{!}{=} \begin{pmatrix} 0 \\ 0 \end{pmatrix} \Rightarrow 3x^2 - 12 = 0 \Rightarrow x_{1,2} = \pm 2$ und $2y = 0 \Rightarrow y = 0$. Kandidaten: $P_1(2, 0), P_2(-2, 0)$

2. Hesse-Matrix:

$H_f(x, y) = \begin{pmatrix} f_{xx} & f_{xy} \\ f_{yx} & f_{yy} \end{pmatrix}$

(Symmetrisch, da $f_{xy} = f_{yx}$)

Bsp: $H_f(x, y) = \begin{pmatrix} 6x & 0 \\ 0 & 2 \end{pmatrix}$

$H_f(x, y) = H_f^T = \begin{pmatrix} \frac{\partial^2}{\partial x^2} f & \frac{\partial^2}{\partial x \partial y} f & \frac{\partial^2}{\partial x^2} f \\ \frac{\partial^2}{\partial y \partial x} f & \frac{\partial^2}{\partial y^2} f & \frac{\partial^2}{\partial y \partial x} f \\ \frac{\partial^2}{\partial x^2} f & \frac{\partial^2}{\partial x \partial y} f & \frac{\partial^2}{\partial x^2} f \end{pmatrix}$

3. Definitheit (über quadratische Form):

Hesse-Matrix $H_f = \begin{pmatrix} a & b & d \\ b & c & e \\ d & e & f \end{pmatrix}$ aufstellen $\rightarrow$ quadratische Form:

$q(u, v, w) = \begin{pmatrix} u & v & w \end{pmatrix} \begin{pmatrix} a & b & d \\ b & c & e \\ d & e & f \end{pmatrix} \begin{pmatrix} u \\ v \\ w \end{pmatrix} = au^2 + cv^2 + fw^2 + 2buv + 2dvw + 2evw$

Bringe durch quadratisches Ergänzen in die Form $c_1(u + \dots)^2 + c_2(v + \dots)^2 + c_3w^2$:

- Nur plus (+) $\Rightarrow$ positiv definit $\Rightarrow$ Minimum
- Nur minus (-) $\Rightarrow$ negativ definit $\Rightarrow$ Maximum
- Beides (+ und -) $\Rightarrow$ indefinit $\Rightarrow$ Sattelpunkt
- Klassifikation Bsp:
 - $P_1(2, 0): H_f(2, 0) = \begin{pmatrix} 12 & 0 \\ 0 & 2 \end{pmatrix} \Rightarrow q(u, v) = \begin{pmatrix} u & v \end{pmatrix} \begin{pmatrix} 12 & 0 \\ 0 & 2 \end{pmatrix} \begin{pmatrix} u \\ v \end{pmatrix} = 6u^2 + v^2$ (nur +) $\Rightarrow$ Minimum
 - $P_2(-2, 0): H_f(-2, 0) = \begin{pmatrix} -12 & 0 \\ 0 & 2 \end{pmatrix} \Rightarrow q(u, v) = \begin{pmatrix} u & v \end{pmatrix} \begin{pmatrix} -12 & 0 \\ 0 & 2 \end{pmatrix} \begin{pmatrix} u \\ v \end{pmatrix} = -6u^2 + v^2$ (beides) $\Rightarrow$ Sattelpunkt
- Contour Plots (Höhenlinien):
 - Minima/Maxima: Zentren geschlossener Ringe/Ellipsen.
 - Sattelpunkte: Kreuzungen/Einschnürungen zw. Bergen & Tälern.

Quadratische Ergänzung

1D-Ergänzung:

$f(x) = \underbrace{2x^2 - 4x + 3}_{\text{quadratisch}} = 2(x^2 - 2x) + 3 = 2(x^2 - 2x + 1 - 1) + 3 = 2(x - 1)^2 - 2 + 3 = 2(x - 1)^2 + 1$

- Mehrdimensionale Expansion: (Es müssen immer alle Kombinationen vorhanden sein)

Das Ergebnis für vier Terme $(a + b + c + d)^2$ lautet ausmultipliziert:

$a^2 + b^2 + c^2 + d^2 + 2ab + 2ac + 2ad + 2bc + 2bd + 2cd$


4. THEORIE: PDF, CDF & MAXIMUM LIKELIHOOD (MLE)

A. Wahrscheinlichkeitsdichte (PDF: $f(x)$)

- Bedingung 1: $f(x) \geq 0$ (nie negativ)
- Bedingung 2 (Fläche = 1): $\int_{-\infty}^{\infty} f(x) dx = 1$


B. Kumulative Verteilungsfunktion (CDF: $F(x)$)

- Definition: $F(x) = P(X \leq x) = \int_{-\infty}^x f(t) dt$
- Eigenschaften: $F(-\infty) = 0, F(\infty) = 1$ (monoton steigend)
- Zusammenhang: $f(x) = \frac{d}{dx} F(x)$ (Dichte ist Ableitung der CDF)



C. Stetige Gleichverteilung unif(a, b)

- Dichte (PDF): $f(x) = \frac{1}{b-a}$ für $a \leq x \leq b$, sonst 0
- Verteilung (CDF): $F_X(x) = \frac{x-a}{b-a}$ für $a < x < b$



Stetigkeit: X, Y unabhängig $\Leftrightarrow f_{X,Y}(x, y) = f_X(x) \cdot f_Y(y)$ (sonst abhängig)

E. Maximum Likelihood Estimation (MLE) Ziel: Parameter θ finden, die die Wahrscheinlichkeit der Stichprobe maximieren. Kochbuch (4 Schritte):

- Likelihood $L(\theta)$ aufstellen: $L(\theta) = \prod_{i=1}^n f(x_i; \theta)$
- Log-Likelihood $\ell(\theta)$ (ln anwenden):
 $\ell(\theta) = \ln(L(\theta)) = \sum_{i=1}^n \ln(f(x_i; \theta))$ (Aus Produkt wird Summe)
(Kostenfunktion / Neg. Log-Likelihood: $c(\theta) = -\ell(\theta) = -\sum \ln(f(x_i; \theta))$)
- Ableiten: $\frac{\partial}{\partial \theta} \ell(\theta)$ berechnen.
- Nullsetzen & Auflösen: $\frac{\partial}{\partial \theta} \ell(\theta) \stackrel{!}{=} 0 \Rightarrow \hat{\theta}_{MLE}$

Bernoulli-Likelihood (k Erfolge in n Versuchen):

$L(p) = p^k \cdot (1 - p)^{n-k}$

5. KOCHBUCH: DIE WICHTIGSTEN AUFGABENTYPEN

Typ 1: Normalisierung (Konstante c finden)

- Geg: $f(x) = c \cdot g(x)$ im Intervall $[a, b]$
- Schritt 1: Integral = 1 setzen: $c \cdot \int_a^b g(x) dx = 1$
- Schritt 2: Integral berechnen: $K = \int_a^b g(x) dx$
- Schritt 3: Nach c auflösen: $c \cdot K = 1 \Rightarrow c = \frac{1}{K}$

Typ 2: Wahrscheinlichkeit im Intervall ($P(a \leq X \leq b)$)

- Schritt 1: Integral der PDF von a bis b berechnen:

$P(a \leq X \leq b) = \int_a^b f(x) dx$

Typ 3: Die CDF $F(x)$ herleiten

- Geg: $f(x)$ ab Startwert a
- Schritt 1: Dummy-Variable t nutzen. Integral aufstellen:

$F(x) = \int_a^x f(t) dt$

- Schritt 2: Integrieren, Obergrenze x und Untergrenze a einsetzen.
- Schritt 3: Formal korrekt aufschreiben:

$F(x) = \begin{cases} 0 & \text{für } x < a \\ \text{Ergebnis} & \text{für } x \geq a \end{cases}$

Typ 4: Mit der CDF Wahrscheinlichkeiten berechnen

- Geg: $F(x)$ bekannt. Gesucht: $P(a < X \leq b)$
- Schritt 1: Obere minus untere Grenze einsetzen:

$P(a < X \leq b) = F(b) - F(a)$

(Kein Integrieren mehr!)

Typ 5: Erwartungswert $E(X)$ berechnen

- Schritt 1: Integral über $x \cdot f(x)$ aufstellen:

$E(X) = \int_{-\infty}^{\infty} x \cdot f(x) dx$

Typ 8: Uneigentliche Integrale (z.B. $P(X > a)$)

- Weg 1 (Integral): $\int_a^{\infty} f(x) dx$. Stammfunktion bilden, Obergrenze ∞ einsetzen. Tipp: $e^{-\infty} = 0, \frac{1}{\infty} = 0$.
- Weg 2 (Schneller, falls $F(x)$ bekannt): Gegenwahrscheinlichkeit nutzen:

$P(X > a) = 1 - P(X \leq a) = 1 - F(a)$

Typ 9: Variablentransformation ($Y = g(X)$)

- Geg: Dichte $f_X(x)$ auf $[a, b]$, Transformation $y = g(x)$. Gesucht: $f_Y(y)$
- Grenzen: Alte Grenzen $[a, b]$ in $g(x)$ einsetzen:
 - Wenn g steigend: $[g(a), g(b)]$ | Wenn g fallend: $[g(b), g(a)]$
- Schritt 1 (Umkehrfunktion): Löse $y = g(x)$ nach x auf:

$x = g^{-1}(y)$

- Schritt 2 (Ableitung): Leite x nach y ab:

$$\frac{d}{d}x = \frac{d}{dy}g^{-1}(y)$$

Schritt 3 (Formel & Einsetzen):

$$f_Y(y) = f_X(g^{-1}(y)) \cdot \left| \frac{dx}{dy} \right|$$

Bsp:

$f_X(x) = \frac{1}{2}$ auf $[0, 2]$ und $y = x^2$ ($x \geq 0$):

Grenzen: $x \in [0, 2] \Rightarrow y \in [0^2, 2^2] = [0, 4]$

Schritt 1: $x = \sqrt{y}$

Schritt 2: $\frac{dx}{dy}y = \frac{1}{2\sqrt{y}}$

Schritt 3: $f_Y(y) = f_X(\sqrt{y}) \cdot \left| \frac{1}{2\sqrt{y}} \right| = \frac{1}{2} \cdot \frac{1}{2\sqrt{y}} = \frac{1}{4\sqrt{y}}$ auf $[0, 4]$

Weg 2 (CDF-Methode, z.B. für $Y = X^p$):

1. CDF aufstellen: $F_{Y(y)} = P(Y \leq y) = P(X^p \leq y) = P\left(X \leq y^{\frac{1}{p}}\right) = F_X\left(y^{\frac{1}{p}}\right)$

2. PDF durch Ableiten finden: $f_{Y(y)} = \frac{d}{dy}F_{Y(y)}$

6. NUMERISCHE OPTIMIERUNG: GRADIENT DESCENT & NEWTON

A. Gradientenabstieg (Gradient Descent)

Ziel: Iterativ ein lokales Minimum finden.

Formel:

$$\mathbf{x}_{k+1} = \mathbf{x}_k - \alpha \cdot \nabla f(\mathbf{x}_k)$$

mit α = Lernrate / Step Size > 0

Kochbuch-Bsp: $f(x, y) = x^2 + 2y^2$, Startwert $\mathbf{x}_0 = \begin{pmatrix} 2 \\ 1 \end{pmatrix}$, Lernrate $\alpha = 0.1$. Gesucht $\mathbf{x}_1$:

1. Gradient allgemein: $\nabla f(x, y) = \begin{pmatrix} 2x \\ 4y \end{pmatrix}$

2. $\mathbf{x}_0$ einsetzen: $\nabla f(2, 1) = \begin{pmatrix} 4 \\ 4 \end{pmatrix}$

3. Formel anwenden:

$$\mathbf{x}_1 = \begin{pmatrix} 2 \\ 1 \end{pmatrix} - 0.1 \cdot \begin{pmatrix} 4 \\ 4 \end{pmatrix} = \begin{pmatrix} 2 \\ 1 \end{pmatrix} - \begin{pmatrix} 0.4 \\ 0.4 \end{pmatrix} = \begin{pmatrix} 1.6 \\ 0.6 \end{pmatrix}$$

Verhalten im Contour Plot: Bewegung immer orthogonal (senkrecht) zu den Höhenlinien in Richtung des tiefsten Punktes. Bei zu grosser Lernrate α kann das Minimum übersprungen werden.

Fehlende globale Konvergenz (3 Szenarien):

1. Lokales statt globales Minimum:

Häufigkeit: Sehr wahrscheinlich bei mehreren Minima.

Fix: Verschiedene Startpunkte wählen.

2. Sattelpunkt / Maximum (stat. Punkt):

Häufigkeit: Sehr unwahrscheinlich.

Fix: Anderen Startpunkt wählen.

3. Overshooting / Keine Konvergenz:

Häufigkeit: Wahrscheinlich bei grosser Lernrate α (v.a. in engen Tälern).

Fix: Kleinere Lernrate α wählen.

B. Newton-Verfahren (Newton's Method)

Variante 1: Nullstellensuche (1D): $f(x) = 0$

$$x_{k+1} = x_k - \frac{f(x_k)}{f'}(x_k)$$

Bsp: $f(x) = x^2 - 5$, $x_0 = 2$. Gesucht x_1 : $f'(x) = 2x \Rightarrow x_1 = 2 - \frac{2^2 - 5}{2 \cdot 2} = 2 - \frac{-1}{4} = 2.25$

Variante 2: Minimumsuche (Multivariat): $\nabla f = 0$

Newton-Formel:

$$\mathbf{x}_{k+1} = \mathbf{x}_k - [H_f(\mathbf{x}_k)]^{-1} \cdot \nabla f(\mathbf{x}_k)$$

Hilfsformeln (Komponenten):

Gradient: $\nabla f(x, y) = \begin{pmatrix} f_x \\ f_y \end{pmatrix} = \begin{pmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \end{pmatrix}$

Hesse-Matrix: $H_f(x, y) = \begin{pmatrix} f_{xx} & f_{xy} \\ f_{yx} & f_{yy} \end{pmatrix}$

Diagonal-Matrix Invertierungs-Trick:

$$\begin{pmatrix} a & 0 \\ 0 & b \end{pmatrix}^{-1} = \begin{pmatrix} \frac{1}{a} & 0 \\ 0 & \frac{1}{b} \end{pmatrix}$$

(Kehrwerte der Diagonalelemente)

Bsp: Geg: $f(x, y) = x^2 + 2y^2 + 4y$, Startwert $\mathbf{x}_0 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$. Gesucht $\mathbf{x}_1$:

1. Gradient & Hesse-Matrix allgemein:

$$\nabla f(x, y) = \begin{pmatrix} 2x \\ 4y + 4 \end{pmatrix}, \quad H_f(x, y) = \begin{pmatrix} 2 & 0 \\ 0 & 4 \end{pmatrix}$$

2. Punkt einsetzen: $\nabla f(1, 1) = \begin{pmatrix} 2 \\ 8 \end{pmatrix}, \quad H_f(1, 1) = \begin{pmatrix} 2 & 0 \\ 0 & 4 \end{pmatrix}$

3. H_f invertieren (Diagonal-Trick): $[H_f(1, 1)]^{-1} = \begin{pmatrix} \frac{1}{2} & 0 \\ 0 & \frac{1}{4} \end{pmatrix}$

4. Schritt berechnen ($\Delta \mathbf{x} = -H_f^{-1} \cdot \nabla f$):

$$\Delta \mathbf{x} = - \begin{pmatrix} \frac{1}{2} & 0 \\ 0 & \frac{1}{4} \end{pmatrix} \begin{pmatrix} 2 \\ 8 \end{pmatrix} = \begin{pmatrix} -\frac{1}{2} \cdot 2 \\ -\frac{1}{4} \cdot 8 \end{pmatrix} = \begin{pmatrix} -1 \\ -2 \end{pmatrix}$$

5. Update: $\mathbf{x}_1 = \begin{pmatrix} 1 \\ 1 \end{pmatrix} + \begin{pmatrix} -1 \\ -2 \end{pmatrix} = \begin{pmatrix} 0 \\ -1 \end{pmatrix}$

Alternativer Newton-Schritt über LGS (Extended): Löse $H_f \cdot \Delta \mathbf{x} = -\nabla f$ nach $\Delta \mathbf{x}$ auf (z.B. mit Gauss-LGS), falls H_f nicht einfach invertierbar ist.

Hesse-Matrix Operationen:

Transponieren: Da H_f symmetrisch ist ($f_{xy} = f_{yx}$), gilt immer $H_f^T = H_f$ (allgemein: Zeilen & Spalten vertauschen).

2x2 Invertieren: $\begin{pmatrix} a & b \\ c & d \end{pmatrix}^{-1} = \frac{1}{ad-bc} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}$

ABLEITUNGSREGELN	
Funktion $f(x)$	Ableitung $f'(x) = \frac{d}{dx}f(x)$
c (Konstante)	0
x^n	nx^{n-1}
e^x	e^x
$e^{g(x)}$	$g'(x)e^{g(x)}$ (Kettenregel)
$\ln(x)$	$\frac{1}{x}$
$\ln(g(x))$	$g' \cdot \frac{x}{g(x)}$ (Log.-Trick)
$\sin(x)$	$\cos(x)$
$\cos(x)$	$-\sin(x)$
$\tan(x)$	$\frac{1}{\cos^2(x)} = 1 + \tan^2(x)$
$\arcsin(x)$	$\frac{1}{\sqrt{1-x^2}}$
$\arccos(x)$	$-\frac{1}{\sqrt{1-x^2}}$
Sigmoid $\sigma(x)$	$\sigma(x)(1 - \sigma(x))$ mit $\sigma(x) = \frac{1}{1+e^{-x}}$
$\ln(\sigma(x))$	$1 - \sigma(x)$ (FS23)
Produktregel	$(uv)' = u'v + uv'$
Quotientenregel	$\left(\frac{u}{v}\right)' = \frac{u'v - uv'}{v^2}$
Totale Ableitung	$\frac{d}{dt}f = \frac{\partial f}{\partial x} \frac{dx}{dt} + \frac{\partial f}{\partial y} \frac{dy}{dt}$

INTEGRATIONSREGELN	
Funktion $f(x)$	Integral $\int f(x) dx$
0	C (Integrationskonstante)
x^n ($n \neq -1$)	$\frac{x^{n+1}}{n+1} + C$
$\frac{1}{x}$	$\ln x + C$
e^x	$e^x + C$
e^{ax}	$\frac{1}{a}e^{ax} + C$
$\sin(x)$	$-\cos(x) + C$
$\cos(x)$	$\sin(x) + C$
$\frac{1}{\cos^2(x)}$	$\tan(x) + C$
$\arcsin(x)$	$x \arcsin(x) + \sqrt{1-x^2} + C$
$\arccos(x)$	$x \arccos(x) - \sqrt{1-x^2} + C$
$\frac{a}{x^{a+1}}$	$-x^{-a} + C$ (FS25)

Funktion $f(x)$	Integral $\int f(x) dx$
Part. Integration	$\int uv' dx = uv - \int u'v dx$
Substitution	$\int f(g(x))g'(x) dx = \int f(u) du$
Uneigntl. Int.	$\int_1^\infty \left(\frac{a}{x^{a+1}}\right) dx = 1$ (für $a > 0$)

LOGARITHMUSGESETZE

Regel	Formel
Multiplikation	$\ln(a \cdot b) = \ln(a) + \ln(b)$
Division	$\ln\left(\frac{a}{b}\right) = \ln(a) - \ln(b)$
Potenzierung	$\ln(a^b) = b \cdot \ln(a)$
Konstante 1	$\ln(1) = 0$
Konstante e	$\ln(e) = 1$
Basiswechsel	$\log_b(a) = \frac{\ln(a)}{\ln(b)}$
Spezialfälle	$e^{-\ln(2)} = \frac{1}{2} \quad \quad \ln(e^{-2}) = -2$

7. MACHINE LEARNING: AKTIVIERUNGEN & LOSSES

Aktivierungsfunktionen

Sigmoid (Binary Classification):

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

Ableitung: $\sigma'(z) = \sigma(z)(1 - \sigma(z))$

Softmax (Multi-Class Classification): Für Vektor $z \in \mathbb{R}^K$:

$$\text{Softmax}(z)_i = \frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}}$$

Loss-Funktionen (Kostenfunktionen)

Log Loss / Binary Cross-Entropy (BCE): Für Wahrscheinlichkeit $p = \sigma(z)$ und wahres Label $y \in \{0, 1\}$:

$$\mathcal{L}_{\text{BCE}(y,p)} = -y \ln(p) - (1 - y) \ln(1 - p)$$

Multi-Class Cross-Entropy (CE): Für Vorhersagen $p_i = \text{Softmax}(z)_i$ und wahre Wahrscheinlichkeiten y_i (One-Hot):

$$\mathcal{L}_{\text{CE}(y,p)} = -\sum_{i=1}^K y_i \ln(p_i)$$

Prüfungs-Shortcut (Gradient bzgl. Logit z_i): Gilt bei BCE+Sigmoid sowie CE+Softmax:

$$\frac{\partial \mathcal{L}}{\partial z_i} = p_i - y_i$$

α	0	$\frac{\pi}{6}$	$\frac{\pi}{4}$	$\frac{\pi}{3}$	$\frac{\pi}{2}$	$\frac{2\pi}{3}$	$\frac{3\pi}{4}$	$\frac{5\pi}{6}$	π	$\frac{7\pi}{6}$	$\frac{5\pi}{4}$	$\frac{4\pi}{3}$	$\frac{3\pi}{2}$	$\frac{5\pi}{3}$	$\frac{7\pi}{4}$	$\frac{11\pi}{6}$	2π
α°	0°	30°	45°	60°	90°	120°	135°	150°	180°	210°	225°	240°	270°	300°	315°	330°	360°
$\sin \alpha$	0	$\frac{1}{2}$	$\frac{\sqrt{2}}{2}$	$\frac{\sqrt{3}}{2}$	1	$\frac{\sqrt{3}}{2}$	$\frac{\sqrt{2}}{2}$	$\frac{1}{2}$	0	$-\frac{1}{2}$	$-\frac{\sqrt{2}}{2}$	$-\frac{\sqrt{3}}{2}$	-1	$-\frac{\sqrt{3}}{2}$	$-\frac{\sqrt{2}}{2}$	$-\frac{1}{2}$	0
$\cos \alpha$	1	$\frac{\sqrt{3}}{2}$	$\frac{\sqrt{2}}{2}$	$\frac{1}{2}$	0	$-\frac{1}{2}$	$-\frac{\sqrt{2}}{2}$	$-\frac{\sqrt{3}}{2}$	-1	$-\frac{\sqrt{3}}{2}$	$-\frac{\sqrt{2}}{2}$	$-\frac{1}{2}$	0	$\frac{1}{2}$	$\frac{\sqrt{2}}{2}$	$\frac{\sqrt{3}}{2}$	1
$\text{tg } \alpha$	0	$\frac{1}{\sqrt{3}}$	1	$\sqrt{3}$	-	$-\sqrt{3}$	-1	$-\frac{1}{\sqrt{3}}$	0	$\frac{1}{\sqrt{3}}$	1	$\sqrt{3}$	-	$-\sqrt{3}$	-1	$-\frac{1}{\sqrt{3}}$	0
$\text{ctg } \alpha$	-	$\sqrt{3}$	1	$\frac{1}{\sqrt{3}}$	0	$-\frac{1}{\sqrt{3}}$	-1	$-\sqrt{3}$	-	$\sqrt{3}$	1	$\frac{1}{\sqrt{3}}$	0	$-\frac{1}{\sqrt{3}}$	-1	$-\sqrt{3}$	-