

0. NOTATION & GRUNDLAGEN


Typografie & Dimensionen

- Skalare: $x, \alpha \in \mathbb{R}$ (normal)
- Vektoren (Standard = Spaltenvektor):
 $x \in \mathbb{R}^{n \times 1}$ bzw. Transponiert $x^T \in \mathbb{R}^{1 \times n}$
- Matrizen: $X \in \mathbb{R}^{m \times n}$ (Zeilen m , Spalten n), Eintrag: X_{ij}

Matrix-Vektor-Multiplikation

- Dimensions-Check: $(m \times n) \cdot (n \times 1) \Rightarrow (m \times 1)$
- Regel: Innere Dimensionen (n) müssen gleich sein.

- Kochbuch-Berechnung:
 1. Zeile i im Ergebnis = Skalarprodukt aus i -ter Zeile von A und Vektor x .
 2. Formel: $y_i = \sum_{j=1}^n A_{ij}x_j$



Kronecker-Delta (δ_{ij})

- Definition: $\delta_{ij} = 1$ falls $i = j$, sonst 0.
- 3 goldene Prüfungs-Regeln:
 1. Matrix-Äquivalent: Einheitsmatrix $I = (\delta_{ij})$
 2. Ableitung von Vektoren: $\partial_{\partial^i} x_j = \delta_{ij}$
 3. Filter-Regel: $\sum_j \delta_{ij} f(j) = f(i)$

Bsp: $\sum_{k=1}^n \delta_{km} U_{ki} = U_{mi}$

Mitternachtsformel (a-b-c-Formel)

Löse $ax^2 + bx + c = 0$ über:

$$x_{1,2} = \frac{-b \pm \sqrt{b^2 - 4ac}}{2a}$$

1. VEKTOREN: LINEARKOMBINATION & UNABHÄNGIGKEIT

Linearkombination (LK)

- $v = \lambda_1 v_1 + \dots + \lambda_k v_k$
- Kochbuch (LGS): Matrix $[A \mid v]$ aufstellen (Vektoren als Spalten) und mit Gauss lösen:
 - Lösbar $\Rightarrow$ Ja (ist LK)
 - Widerspruch (z.B. $0 = c$) $\Rightarrow$ Nein (keine LK)
 - Bsp: $\begin{pmatrix} 1 & 2 & 5 \\ 0 & 1 & 2 \end{pmatrix} \Rightarrow$ lösbar.

Lineare Unabhängigkeit (LU)

$\sum \lambda_i v_i = 0 \Rightarrow \lambda_1 = \dots = \lambda_k = 0$ (nur triviale Lösung)

- Kochbuch (Vektoren als Spalten in Matrix A):
Bringe $[A \mid 0]$ mit Gauss auf Zeilenstufenform.
 - Jede Spalte hat ein Pivot-Element $\Rightarrow$ LU
 - Spalte ohne Pivot (freie Variable) $\Rightarrow$ LA

Bsp: $v_1 = \begin{pmatrix} 1 \\ 0 \\ 2 \end{pmatrix}, v_2 = \begin{pmatrix} 2 \\ 1 \\ 0 \end{pmatrix}, v_3 = \begin{pmatrix} 0 \\ -1 \\ 4 \end{pmatrix} \Rightarrow [A \mid 0] =$

$\begin{pmatrix} 1 & 2 & 0 & | & 0 \\ 0 & 1 & -1 & | & 0 \\ 2 & 0 & 4 & | & 0 \end{pmatrix} \xrightarrow{\text{Gauss}} \begin{pmatrix} 1 & 2 & 0 & | & 0 \\ 0 & 1 & -1 & | & 0 \\ 0 & -4 & 4 & | & 0 \end{pmatrix} \Rightarrow \begin{pmatrix} 1 & 2 & 0 & | & 0 \\ 0 & 1 & -1 & | & 0 \\ 0 & 0 & 0 & | & 0 \end{pmatrix} \Rightarrow$ Spalte 3 ohne Pivot $\Rightarrow$ LA.

2. MULTIVARIATE ABLEITUNGEN

Gradient ∇f (Skalar $\rightarrow$ Vektor)

- $f: \mathbb{R}^n \rightarrow \mathbb{R}$ (Spaltenvektor der partiellen Ableitungen).
(Regel: Man leitet nur nach der gesuchten Variable ab. Alle anderen Variablen werden wie Konstanten / Zahlen behandelt.)
- Bsp: $f(x, y) = x^2 y + 3y \Rightarrow \partial_x^1 f = 2xy, \partial_y^1 f = x^2 + 3 \Rightarrow \nabla f(x, y) = \begin{pmatrix} 2xy \\ x^2 + 3 \end{pmatrix}$
- Vektor-Gradienten:

$|\cdot|: \begin{cases} \mathbb{R}^n \rightarrow \mathbb{R}^+ \\ x \mapsto \sqrt{\sum_{i=1}^n x_i^2} \end{cases}$

$|u| = \sqrt{u^T u} = \sqrt{\sum_k u_k^2}$

$\nabla |u| = \frac{1}{|u|} u^T$
 $\nabla (x^T x) = \nabla |x|^2 = 2x^T$

(Hinweis: $x^T x$ ist reell. $\frac{1}{|x|} = (\sum_{i=1}^n x_i^2)^{-\frac{1}{2}}$)

Jacobi-Matrix J_f (Vektor $\rightarrow$ Matrix)

$f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ (Grösse $m \times n$). Zeile i = Ableitungen von f_i nach allen Variablen.

• Bsp: $f(x, y) = \begin{pmatrix} x^2 y \\ 5x + y \end{pmatrix} \Rightarrow J_f = \begin{pmatrix} \frac{\partial f_1}{\partial x_1}(P) & \dots & \frac{\partial f_1}{\partial x_n}(P) \\ \vdots & \ddots & \vdots \\ \frac{\partial f_m}{\partial x_1}(P) & \dots & \frac{\partial f_m}{\partial x_n}(P) \end{pmatrix}$
(Hinweis: $\nabla f = J_f^T$)

Mehrdimensionale Kettenregel

$J_{f \circ g}(x) = J_{f(g(x))} \cdot J_{g(x)}$

Für 3 + Funktionen:

$J_{f \circ g \circ h}(x) = J_{f(g(h(x)))} \cdot J_{g(h(x))} \cdot J_{h(x)}$
(Matrizenmultiplikation von links nach rechts)

• Kochbuch-Bsp (Ableitung entlang Kurve):

Gegeben $f(x, y) = x \cdot y$ und Kurve $c(t) = \begin{pmatrix} 3t \\ t^2 \end{pmatrix}$. Gesucht $\frac{d}{dt} f(c(t))$:



1. Äussere Ableitung: $J_f(x, y) = \begin{pmatrix} y & x \end{pmatrix}$
2. Kurve in J_f einsetzen: $J_f(c(t)) = \begin{pmatrix} 3t & t^2 \end{pmatrix}$
3. Innere Ableitung: $J_c(t) = c'(t) = \begin{pmatrix} 3 \\ 2t \end{pmatrix}$
4. Multiplikation: $\begin{pmatrix} 3t & t^2 \end{pmatrix} \cdot \begin{pmatrix} 3 \\ 2t \end{pmatrix} = 3t \cdot 3 + t^2 \cdot 2t = 9t + 2t^3$

Mehrdimensionale Linearisierung

Approximation 1. Ordnung von $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ an der Stelle $a \in \mathbb{R}^n$:

$f(x) \approx f(a) + J_f(a) \cdot (x - a)$

- Bsp: $f(x, y) = \begin{pmatrix} x^2 + y^2 \\ xy \end{pmatrix}$ an der Stelle $a = \begin{pmatrix} 1 \\ 2 \end{pmatrix}$.
 1. $f(a) = \begin{pmatrix} 1^2 + 2^2 \\ 1 \cdot 2 \end{pmatrix} = \begin{pmatrix} 5 \\ 2 \end{pmatrix}$
 2. Jacobi: $J_f(x, y) = \begin{pmatrix} 2x & 2y \\ y & x \end{pmatrix} \Rightarrow J_f(a) = \begin{pmatrix} 2 & 4 \\ 2 & 1 \end{pmatrix}$
 3. Formel:

$\tilde{f}(x, y) = \begin{pmatrix} 5 \\ 2 \end{pmatrix} + \begin{pmatrix} 2 & 4 \\ 2 & 1 \end{pmatrix} \begin{pmatrix} x - 1 \\ y - 2 \end{pmatrix} = \begin{pmatrix} 2x + 4y - 5 \\ 2x + y - 2 \end{pmatrix}$

4. Approx. für $x = \begin{pmatrix} 1.01 \\ 1.98 \end{pmatrix}$ (nahe a):

$\tilde{f}(1.01, 1.98) = \begin{pmatrix} 5 \\ 2 \end{pmatrix} + \begin{pmatrix} 2 & 4 \\ 2 & 1 \end{pmatrix} \begin{pmatrix} 0.01 \\ -0.02 \end{pmatrix} = \begin{pmatrix} 4.94 \\ 2.00 \end{pmatrix}$

(Exakt: $f(1.01, 1.98) = \begin{pmatrix} 4.9405 \\ 1.9998 \end{pmatrix}$)

3. OPTIMIERUNG: STATIONÄRE PUNKTE & HESSE-MATRIX

Ziel: Lokale Extrema finden & klassifizieren für $f(x, y)$.

- Bsp: $f(x, y) = x^3 - 12x + y^2$

1. Stationäre Punkte: $\nabla f(x, y) = \begin{pmatrix} 3x^2 - 12 \\ 2y \end{pmatrix} \stackrel{!}{=} \begin{pmatrix} 0 \\ 0 \end{pmatrix} \Rightarrow 3x^2 - 12 = 0 \Rightarrow x_{1,2} = \pm 2$ und $2y = 0 \Rightarrow y = 0$. Kandidaten: $P_1(2, 0), P_2(-2, 0)$
(Tipp: Mit Fällen arbeiten und in die andere Gleichung einsetzen!)
 - LGS-Lösungsstrategien für $\nabla f = 0$:

- **S1: Ausklammern & Nullprodukt** (Trick): Nie durch Variable teilen! $xy = 2x \Rightarrow xy - 2x = 0 \Rightarrow x(y - 2) = 0 \Rightarrow$ Fall 1: $x = 0$, Fall 2: $y = 2$. Fälle einzeln in andere Gleichung einsetzen.
- **S2: Einsetzungsverfahren** (Zuverlässig): Einfachste Gleichung nach einer Variable auflösen und in andere einsetzen. Bsp: $2x - y = 0 \Rightarrow y = 2x$ in (II) einsetzen.
- **S3: Subtraktion** (Symmetrie-Trick): Bei fast identischen Gleichungen (I) - (II) rechnen. Oft entsteht $x^2 - y^2 = (x - y)(x + y) = 0 \Rightarrow$ S1 anwenden.

2. Hesse-Matrix:

$H_f(x, y) = \begin{pmatrix} f_{xx} & f_{xy} \\ f_{xy} & f_{yy} \end{pmatrix}$

(In Prüfungsaufgaben meist symmetrisch, da $f_{xy} = f_{yx}$)

$H_f(x, y) = H_f^T = \begin{pmatrix} \frac{\partial^2}{\partial x^2} f & \frac{\partial^2}{\partial x \partial y} f & \frac{\partial^2}{\partial y \partial x} f \\ \frac{\partial^2}{\partial y \partial x} f & \frac{\partial^2}{\partial y^2} f & \frac{\partial^2}{\partial x \partial y} f \end{pmatrix}$

- Bsp: $H_f(x, y) = \begin{pmatrix} 6x & 0 \\ 0 & 2 \end{pmatrix}$

3. Punkte einsetzen: Falls Variablen in $H_f(x, y)$ existieren (z.B. x im Bsp.), jeden stationären Punkt P_i einzeln in H_f einsetzen, um für jeden Punkt eine konstante Matrix zu erhalten.

4. Definitheit (über quadratische Form):

Hesse-Matrix $H_f = \begin{pmatrix} a & b & d \\ b & c & e \\ d & e & f \end{pmatrix}$ aufstellen $\rightarrow$ quadratische Form:

$q(u, v, w) = \begin{pmatrix} u & v & w \end{pmatrix} \begin{pmatrix} a & b & d \\ b & c & e \\ d & e & f \end{pmatrix} \begin{pmatrix} u \\ v \\ w \end{pmatrix} = au^2 + cv^2 + fw^2 + 2buv + 2dvw + 2evw$

Bringe durch quadratisches Ergänzen in die Form $c_1(u + \dots)^2 + c_2(v + \dots)^2 + c_3w^2$:

- Nur plus (+) $\Rightarrow$ positiv definit $\Rightarrow$ Minimum
- Nur minus (-) $\Rightarrow$ negativ definit $\Rightarrow$ Maximum
- Beides (+ und -) $\Rightarrow$ indefinit $\Rightarrow$ Sattelpunkt
- Klassifikation Bsp:
 - $P_1(2, 0): H_f(2, 0) = \begin{pmatrix} 12 & 0 \\ 0 & 2 \end{pmatrix} \Rightarrow q(u, v) = \begin{pmatrix} u & v \end{pmatrix} \begin{pmatrix} 12 & 0 \\ 0 & 2 \end{pmatrix} \begin{pmatrix} u \\ v \end{pmatrix} = 12u^2 + 2v^2$ (nur +) $\Rightarrow$ Minimum
 - $P_2(-2, 0): H_f(-2, 0) = \begin{pmatrix} -12 & 0 \\ 0 & 2 \end{pmatrix} \Rightarrow q(u, v) = \begin{pmatrix} u & v \end{pmatrix} \begin{pmatrix} -12 & 0 \\ 0 & 2 \end{pmatrix} \begin{pmatrix} u \\ v \end{pmatrix} = -12u^2 + 2v^2$ (beides) $\Rightarrow$ Sattelpunkt
- Contour Plots (Höhenlinien):
 - Minima/Maxima: Zentren geschlossener Ringe/Ellipsen.
 - Sattelpunkte: Kreuzungen/Einschnürungen zw. Bergen & Tälern.

Quadratische Ergänzung

- 1D-Ergänzung:

$f(x) = \frac{2x^2 - 4x + 3}{x^2 + 4} = \frac{2x^2 - 4x + 4 - 4 + 3}{x^2 + 4} = \frac{2x^2 - 4x + 4}{x^2 + 4} - \frac{1}{x^2 + 4} = 2 \left(\frac{x^2 - 2x + 2}{x^2 + 4} \right) - \frac{1}{x^2 + 4}$

- Mehrdimensionale Expansion: (Es müssen immer alle Kombinationen vorhanden sein)

Das Ergebnis für vier Terme $(a + b + c + d)^2$ lautet ausmultipliziert:

$a^2 + b^2 + c^2 + d^2 + 2ab + 2ac + 2ad + 2bc + 2bd + 2cd$


4. THEORIE: PDF, CDF & MAXIMUM LIKELIHOOD (MLE)

A. Wahrscheinlichkeitsdichte (PDF: $f(x)$)

- Bedingung 1: $f(x) \geq 0$ (nie negativ)
- Bedingung 2 (Fläche = 1): $\int_{-\infty}^{\infty} f(x) dx = 1$


B. Kumulative Verteilungsfunktion (CDF: $F(x)$)

- Definition: $F(x) = P(X \leq x) = \int_{-\infty}^x f(t) dt$
- Eigenschaften: $F(-\infty) = 0, F(\infty) = 1$ (monoton steigend)



C. Stetige Gleichverteilung unif(a, b)

- Dichte (PDF): $f(x) = \frac{1}{b-a}$ für $a \leq x \leq b$, sonst 0
- Verteilung (CDF): $F_X(x) = \frac{x-a}{b-a}$ für $a < x < b$



D. Statistische Unabhängigkeit X, Y unabhängig $\Leftrightarrow f_{X,Y}(x, y) = f_X(x) \cdot f_Y(y)$ (sonst abhängig)

- Bsp (unabhängig): $f(x, y) = 4xy$ für $0 \leq x, y \leq 1$, sonst 0.
 - $f_X(x) = \int_0^1 4xy dy = [2xy^2]_{y=0}^1 = 2x$ für $0 \leq x \leq 1$
 - $f_Y(y) = \int_0^1 4xy dx = [2x^2y]_{x=0}^1 = 2y$ für $0 \leq y \leq 1$
 - Check: $f_X(x) \cdot f_Y(y) = 2x \cdot 2y = 4xy = f(x, y) \Rightarrow$ unabhängig.

E. Maximum Likelihood Estimation (MLE) Ziel: Parameter θ finden, die die Wahrscheinlichkeit der Stichprobe maximieren. Kochbuch (4 Schritte):

1. Likelihood $L(\theta)$ aufstellen: $L(\theta) = \prod_{i=1}^n f(x_i; \theta)$
2. Log-Likelihood $\ell(\theta)$ (In anwenden):
 $\ell(\theta) = \ln(L(\theta)) = \sum_{i=1}^n \ln(f(x_i; \theta))$ (Aus Produkt wird Summe)
(Kostenfunktion / Neg. Log-Likelihood: $c(\theta) = -\ell(\theta) = -\sum \ln(f(x_i; \theta))$)
3. Ableiten: $\frac{\partial}{\partial \theta} \ell(\theta)$ berechnen.
4. Nullsetzen & Auflösen: $\frac{\partial}{\partial \theta} \ell(\theta) \stackrel{!}{=} 0 \Rightarrow \hat{\theta}_{MLE}$

- Bernoulli-Likelihood (k Erfolge in n Versuchen):
 $L(p) = p^k \cdot (1 - p)^{n-k}$

5. KOCHBUCH: DIE WICHTIGSTEN AUFGABENTYPEN

Typ 1: Normalisierung (Konstante c finden)

- Geg: $f(x) = c \cdot g(x)$ im Intervall $[a, b]$
- Schritt 1: Integral = 1 setzen: $c \cdot \int_a^b g(x) dx = 1$
- Schritt 2: Integral berechnen: $K = \int_a^b g(x) dx$
- Schritt 3: Nach c auflösen: $c \cdot K = 1 \Rightarrow c = \frac{1}{K}$

Typ 2: Wahrscheinlichkeit im Intervall ($P(a \leq X \leq b)$)

- Schritt 1: Integral der PDF von a bis b berechnen:

$P(a \leq X \leq b) = \int_a^b f(x) dx$

Typ 3: Die CDF $F(x)$ herleiten

- Geg: $f(x)$ ab Startwert a
- Schritt 1: Dummy-Variablen t nutzen. Integral aufstellen:

$F(x) = \int_a^x f(t) dt$

- Schritt 2: Integrieren, Obergrenze x und Untergrenze a einsetzen.
- Schritt 3: Formal korrekt aufschreiben:

$F(x) = \begin{cases} 0 & \text{für } x < a \\ \text{Ergebnis} & \text{für } x \geq a \end{cases}$

Typ 4: Mit der CDF berechnen

- Geg: $F(x)$ bekannt. Gesucht: $P(a < X \leq b)$
- Schritt 1: Obere minus untere Grenze einsetzen:

$$P(a < X \leq b) = F(b) - F(a)$$

(Kein Integrieren mehr!)

Typ 5: Erwartungswert $E(X)$ berechnen

- Schritt 1: Integral über $x \cdot f(x)$ aufstellen:

$$E(X) = \int_{-\infty}^{\infty} x \cdot f(x) \, dx$$

Typ 8: Uneigentliche Integrale (z.B. $P(X > a)$)

- Weg 1 (Integral): $\int_a^{\infty} f(x) \, dx$. Stammfunktion bilden, Obergrenze ∞ einsetzen. Tipp: $e^{-\infty} = 0, \frac{1}{\infty} = 0$.
- Weg 2 (Schneller, falls $F(x)$ bekannt): Gegenwahrscheinlichkeit nutzen:

$$P(X > a) = 1 - P(X \leq a) = 1 - F(a)$$

Typ 9: Variablentransformation ($Y = g(X)$)

- Geg: Dichte $f_X(x)$ auf $[a, b]$, Transformation $y = g(x)$. Gesucht: $f_Y(y)$
- Grenzen: Alte Grenzen $[a, b]$ in $g(x)$ einsetzen:
 - Wenn g steigend: $[g(a), g(b)]$ | Wenn g fallend: $[g(b), g(a)]$
- Schritt 1 (Umkehrfunktion): Löse $y = g(x)$ nach x auf:

$$x = g^{-1}(y)$$

- Schritt 2 (Ableitung): Leite x nach y ab:

$$\frac{dx}{dy} = \frac{1}{\frac{dy}{dx}}$$

- Schritt 3 (Formel & Einsetzen):

$$f_Y(y) = f_X(g^{-1}(y)) \cdot \left| \frac{dx}{dy} \right|$$

- Bsp: $f_X(x) = \frac{1}{2}$ auf $[0, 2]$ und $y = x^2$ ($x \geq 0$):
 - Grenzen: $x \in [0, 2] \Rightarrow y \in [0^2, 2^2] = [0, 4]$
 - Schritt 1: $x = \sqrt{y}$
 - Schritt 2: $\frac{dx}{dy} = \frac{1}{2\sqrt{y}}$
 - Schritt 3: $f_Y(y) = f_X(\sqrt{y}) \cdot \left| \frac{1}{2\sqrt{y}} \right| = \frac{1}{2} \cdot \frac{1}{2\sqrt{y}} = \frac{1}{4\sqrt{y}}$ auf $[0, 4]$
- Weg 2 (CDF-Methode, z.B. für $Y = X^p$):
 - CDF aufstellen: $F_{Y(y)} = P(Y \leq y) = P(X^p \leq y) = P\left(X \leq y^{\frac{1}{p}}\right) = F_X\left(y^{\frac{1}{p}}\right)$
 - PDF durch Ableiten finden: $f_{Y(y)} = \frac{d}{dy} F_{Y(y)}$

6. NUMERISCHE OPTIMIERUNG: GRADIENT DESCENT & NEWTON

A. Gradientenabstieg (Gradient Descent)

- Ziel: Iterativ ein lokales Minimum finden.
- Formel:

$$\mathbf{x}_{k+1} = \mathbf{x}_k - \alpha \cdot \nabla f(\mathbf{x}_k)$$

mit α = Lernrate / Step Size > 0

- Kochbuch-Bsp: $f(x, y) = x^2 + 2y^2$, Startwert $\mathbf{x}_0 = \begin{pmatrix} 2 \\ 1 \end{pmatrix}$, Lernrate $\alpha = 0.1$. Gesucht $\mathbf{x}_1$:
 - Gradient allgemein: $\nabla f(x, y) = \begin{pmatrix} 2x \\ 4y \end{pmatrix}$
 - $\mathbf{x}_0$ einsetzen: $\nabla f(2, 1) = \begin{pmatrix} 4 \\ 4 \end{pmatrix}$
 - Formel anwenden:

$$\mathbf{x}_1 = \begin{pmatrix} 2 \\ 1 \end{pmatrix} - 0.1 \cdot \begin{pmatrix} 4 \\ 4 \end{pmatrix} = \begin{pmatrix} 2 \\ 1 \end{pmatrix} - \begin{pmatrix} 0.4 \\ 0.4 \end{pmatrix} = \begin{pmatrix} 1.6 \\ 0.6 \end{pmatrix}$$

- Verhalten im Contour Plot: Bewegung immer orthogonal (senkrecht) zu den Höhenlinien in Richtung des tiefsten Punktes. Bei zu grosser Lernrate α kann das Minimum übersprungen werden.
- Fehlende globale Konvergenz (3 Szenarien):
 - Lokales statt globales Minimum:

- Häufigkeit: Sehr selten bei mehreren Minima.
- Fix: Verschiedene Startpunkte wählen.

- Sattelpunkt / Maximum (stat. Punkt):
 - Häufigkeit: Sehr unwahrscheinlich.
 - Fix: Anderen Startpunkt wählen.
- Overshooting / Keine Konvergenz:
 - Häufigkeit: Wahrscheinlich bei grosser Lernrate α (v.a. in engen Tälern).
 - Fix: Kleinere Lernrate α wählen.

B. Newton-Verfahren (Newton's Method)

- Variante 1: Nullstellensuche (1D): $f'(x) = 0$

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}$$

- Bsp: $f(x) = x^2 - 5, x_0 = 2$. Gesucht x_1 : $f'(x) = 2x \Rightarrow x_1 = 2 - \frac{2^2 - 5}{2 \cdot 2} = 2 - \frac{-1}{4} = 2.25$

- Variante 2: Minimumsuche (Multivariat): $\nabla f = 0$
- Newton-Formel:

$$\mathbf{x}_{k+1} = \mathbf{x}_k - [\mathbf{H}_f(\mathbf{x}_k)]^{-1} \cdot \nabla f(\mathbf{x}_k)$$

- Hilfsformeln (Komponenten):

Gradient: $\nabla f(x, y) = \begin{pmatrix} f_x \\ f_y \end{pmatrix} = \begin{pmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \end{pmatrix}$

Hesse-Matrix: $\mathbf{H}_f(x, y) = \begin{pmatrix} f_{xx} & f_{xy} \\ f_{yx} & f_{yy} \end{pmatrix}$

- Diagonal-Matrix Invertierungs-Trick:

$$\begin{pmatrix} a & 0 \\ 0 & b \end{pmatrix}^{-1} = \begin{pmatrix} \frac{1}{a} & 0 \\ 0 & \frac{1}{b} \end{pmatrix}$$

(Kehrwerte der Diagonalelemente)

- Bsp: Geg: $f(x, y) = x^2 + 2y^2 + 4y$, Startwert $\mathbf{x}_0 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$. Gesucht $\mathbf{x}_1$:
 - Gradient & Hesse-Matrix allgemein:

$$\nabla f(x, y) = \begin{pmatrix} 2x \\ 4y + 4 \end{pmatrix}, \quad \mathbf{H}_f(x, y) = \begin{pmatrix} 2 & 0 \\ 0 & 4 \end{pmatrix}$$

- Punkt einsetzen: $\nabla f(1, 1) = \begin{pmatrix} 2 \\ 8 \end{pmatrix}, \quad \mathbf{H}_f(1, 1) = \begin{pmatrix} 2 & 0 \\ 0 & 4 \end{pmatrix}$
- $\mathbf{H}_f$ invertieren (Diagonal-Trick): $[\mathbf{H}_f(1, 1)]^{-1} = \begin{pmatrix} \frac{1}{2} & 0 \\ 0 & \frac{1}{4} \end{pmatrix}$
- Schritt berechnen ($\Delta \mathbf{x} = -\mathbf{H}_f^{-1} \cdot \nabla f$):

$$\Delta \mathbf{x} = - \begin{pmatrix} \frac{1}{2} & 0 \\ 0 & \frac{1}{4} \end{pmatrix} \begin{pmatrix} 2 \\ 8 \end{pmatrix} = \begin{pmatrix} -\frac{1}{2} \cdot 2 \\ -\frac{1}{4} \cdot 8 \end{pmatrix} = \begin{pmatrix} -1 \\ -2 \end{pmatrix}$$

- Update: $\mathbf{x}_1 = \begin{pmatrix} 1 \\ 1 \end{pmatrix} + \begin{pmatrix} -1 \\ -2 \end{pmatrix} = \begin{pmatrix} 0 \\ -1 \end{pmatrix}$
- Alternativer Newton-Schritt über LGS (Extended): Löse $\mathbf{H}_f \cdot \Delta \mathbf{x} = -\nabla f$ nach $\Delta \mathbf{x}$ auf (z.B. mit Gauss-LGS), falls $\mathbf{H}_f$ nicht einfach invertierbar ist.

- Hesse-Matrix Operationen:

- Transponieren: Da $\mathbf{H}_f$ symmetrisch ist ($f_{xy} = f_{yx}$), gilt immer $\mathbf{H}_f^T = \mathbf{H}_f$ (allgemein: Zeilen & Spalten vertauschen).
- 2x2 Invertieren: $\begin{pmatrix} a & b \\ c & d \end{pmatrix}^{-1} = \frac{1}{ad-bc} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}$

ABLEITUNGSREGELN

Funktion $f(x)$	Ableitung $f'(x) = \frac{d}{dx}x$
c (Konstante)	0
x	1
x^2	2x
x^n	nx^{n-1}
$\frac{1}{x}$	$-\frac{1}{x^2}$
$\sqrt{x}$	$\frac{1}{2\sqrt{x}}$
e^x	e^x
$e^{g(x)}$	$g'(x)e^{g(x)}$ (Kettenregel)
a^x	$\ln(a)a^x$

Funktion $f(x)$	Ableitung $f'(x) = \frac{d}{dx}x$
$\ln(x)$	$\frac{1}{x}$
$\ln(g(x))$	$g' \cdot \frac{x}{g(x)}$ (Log.-Trick)
$\log_b(x)$	$\frac{1}{\ln(b)x}$
$\sin(x)$	$\cos(x)$
$\cos(x)$	$-\sin(x)$
$\tan(x)$	$\frac{1}{\cos^2(x)} = 1 + \tan^2(x)$
$\arcsin(x)$	$\frac{1}{\sqrt{1-x^2}}$
$\arccos(x)$	$-\frac{1}{\sqrt{1-x^2}}$
$\arctan(x)$	$\frac{1}{1+x^2}$
Sigmoid $\sigma(x)$	$\sigma(x)(1 - \sigma(x))$ mit $\sigma(x) = \frac{1}{1+e^{-x}}$
$\ln(\sigma(x))$	$1 - \sigma(x)$ (FS23)
Produktregel	$(uv)' = u'v + uv'$
Quotientenregel	$\left(\frac{u}{v}\right)' = \frac{u'v - uv'}{v^2}$
Totale Ableitung	$\frac{d}{dt}t = \frac{\partial}{\partial x}x \frac{dx}{dt} + \frac{\partial}{\partial y}y \frac{dy}{dt}$

INTEGRATIONSREGELN

Nach dem Integrieren + C nicht vergessen!

Funktion $f(x)$	Integral $\int f(x) \, dx$
0	C (Integrationskonstante)
K (Konstante)	$Kx + C$
x^n ($n \neq -1$)	$\frac{x^{n+1}}{n+1} + C$
$\sqrt{x}$	$\frac{2}{3}x^{\frac{3}{2}} + C$
$\frac{1}{\sqrt{x}}$	$2\sqrt{x} + C$
$\frac{1}{x}$	$\ln x + C$
e^x	$e^x + C$
e^{ax}	$\frac{1}{a}e^{ax} + C$
a^x	$\frac{1}{\ln(a)}a^x + C$
$\sin(x)$	$-\cos(x) + C$
$\cos(x)$	$\sin(x) + C$
$\frac{1}{\cos^2(x)}$	$\tan(x) + C$
$\frac{1}{\sqrt{1-x^2}}$	$\arcsin(x) + C$
$\frac{1}{1+x^2}$	$\arctan(x) + C$
$\ln(x)$	$x \ln(x) - x + C$
$\arcsin(x)$	$x \arcsin(x) + \sqrt{1-x^2} + C$
$\arccos(x)$	$x \arccos(x) - \sqrt{1-x^2} + C$
$\frac{a}{x^a+1}$	$-x^{-a} + C$ (FS25)
Part. Integration	$\int uv' \, dx = uv - \int u'v \, dx$
Substitution	$\int f(g(x))g'(x) \, dx = \int f(u) \, du$
Uneigentl. Int.	$\int_1^{\infty} \left(\frac{a}{x^{a+1}}\right) dx = 1$ (für $a > 0$)


LOGARITHMUSGESETZE

Regel	Formel
Multiplikation	$\ln(a \cdot b) = \ln(a) + \ln(b)$
Division	$\ln\left(\frac{a}{b}\right) = \ln(a) - \ln(b)$
Potenzierung	$\ln(a^b) = b \cdot \ln(a)$
Konstante 1	$\ln(1) = 0$
Konstante e	$\ln(e) = 1$
Basiswechsel	$\log_b(a) = \frac{\ln(a)}{\ln(b)}$
Spezialfälle	$e^{-\ln(2)} = \frac{1}{2} \quad \quad \ln(e^{-2}) = -2$

7. MACHINE LEARNING: AKTIVIERUNGEN & LOSSES

Aktivierungsfunktionen

- Sigmoid (Binary Classification):



$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

Ableitung: $\sigma'(z) = \sigma(z)(1 - \sigma(z))$

- Softmax (Multi-Class Classification): Für Vektor $\mathbf{z} \in \mathbb{R}^K$:

$$\text{Softmax}(\mathbf{z})_i = \frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}}$$

Loss-Funktionen (Kostenfunktionen)

- Log Loss / Binary Cross-Entropy (BCE): Für Wahrscheinlichkeit $p = \sigma(z)$ und wahres Label $y \in \{0, 1\}$:

$$\mathcal{L}_{\text{BCE}(y,p)} = -y \ln(p) - (1 - y) \ln(1 - p)$$

- Multi-Class Cross-Entropy (CE): Für Vorhersagen $p_i = \text{Softmax}(\mathbf{z})_i$ und wahre Wahrscheinlichkeiten y_i (One-Hot):

$$\mathcal{L}_{\text{CE}(y,p)} = - \sum_{i=1}^K y_i \ln(p_i)$$

- Prüfungs-Shortcut (Gradient bzgl. Logit z_i): Gilt bei BCE+Softmax sowie CE+Softmax:

$$\frac{\partial \mathcal{L}}{\partial z_i} = p_i - y_i$$

TRIGONOMETRISCHE WERTE

$$\tan(x) = \frac{\sin(x)}{\cos(x)}$$

α	0	$\frac{\pi}{6}$	$\frac{\pi}{4}$	$\frac{\pi}{3}$	$\frac{\pi}{2}$	$\frac{2\pi}{3}$	$\frac{3\pi}{4}$	$\frac{5\pi}{6}$	π	$\frac{7\pi}{6}$	$\frac{5\pi}{4}$	$\frac{4\pi}{3}$	$\frac{3\pi}{2}$	$\frac{5\pi}{3}$	$\frac{7\pi}{4}$	$\frac{11\pi}{6}$	2π
α°	0°	30°	45°	60°	90°	120°	135°	150°	180°	210°	225°	240°	270°	300°	315°	330°	360°
$\sin \alpha$	0	$\frac{1}{2}$	$\frac{\sqrt{2}}{2}$	$\frac{\sqrt{3}}{2}$	1	$\frac{\sqrt{3}}{2}$	$\frac{\sqrt{2}}{2}$	$\frac{1}{2}$	0	$-\frac{1}{2}$	$-\frac{\sqrt{2}}{2}$	$-\frac{\sqrt{3}}{2}$	-1	$-\frac{\sqrt{3}}{2}$	$-\frac{\sqrt{2}}{2}$	$-\frac{1}{2}$	0
$\cos \alpha$	1	$\frac{\sqrt{3}}{2}$	$\frac{\sqrt{2}}{2}$	$\frac{1}{2}$	0	$-\frac{1}{2}$	$-\frac{\sqrt{2}}{2}$	$-\frac{\sqrt{3}}{2}$	-1	$-\frac{\sqrt{3}}{2}$	$-\frac{\sqrt{2}}{2}$	$-\frac{1}{2}$	0	$\frac{1}{2}$	$\frac{\sqrt{2}}{2}$	$\frac{\sqrt{3}}{2}$	1
$\tan \alpha$	0	$\frac{1}{\sqrt{3}}$	1	$\sqrt{3}$	-	$-\sqrt{3}$	-1	$-\frac{1}{\sqrt{3}}$	0	$\frac{1}{\sqrt{3}}$	1	$\sqrt{3}$	-	$-\sqrt{3}$	-1	$-\frac{1}{\sqrt{3}}$	0
$\csc \alpha$	-	$\sqrt{3}$	1	$\frac{1}{\sqrt{3}}$	0	$-\frac{1}{\sqrt{3}}$	-1	$-\sqrt{3}$	-	$\sqrt{3}$	1	$\frac{1}{\sqrt{3}}$	0	$-\frac{1}{\sqrt{3}}$	-1	$-\sqrt{3}$	-

WICHTIGE KONSTANTEN & GRENZWERTE

Ausdruck / Limes	Wert
e^0	1
e^1	$e \approx 2.718$
$e^{-1} = \frac{1}{e}$	≈ 0.368
π	≈ 3.1415
$\sqrt{2}$	≈ 1.414
$\sqrt{3}$	≈ 1.732
$\lim_{x \rightarrow \infty} \frac{1}{x}$	0
$\lim_{x \rightarrow 0^+} \frac{1}{x}$	$+\infty$
$\lim_{x \rightarrow 0^-} \frac{1}{x}$	$-\infty$
$\lim_{x \rightarrow \infty} e^x$	∞
$\lim_{x \rightarrow -\infty} e^x$	0
$\lim_{x \rightarrow \infty} \ln(x)$	∞
$\lim_{x \rightarrow 0^+} \ln(x)$	$-\infty$
$\lim_{x \rightarrow \infty} x^n e^{-x}$	0
$\lim_{x \rightarrow \infty} \frac{\ln(x)}{x}$	0
$\lim_{x \rightarrow 0^+} x \ln(x)$	0
$\lim_{x \rightarrow \infty} \left(1 + \frac{a}{x}\right)^x$	e^a
$\lim_{x \rightarrow \infty} \sigma(x)$	1
$\lim_{x \rightarrow -\infty} \sigma(x)$	0